

Mehrkriterielle Optimierung

6.3.2012

Carsten Franke

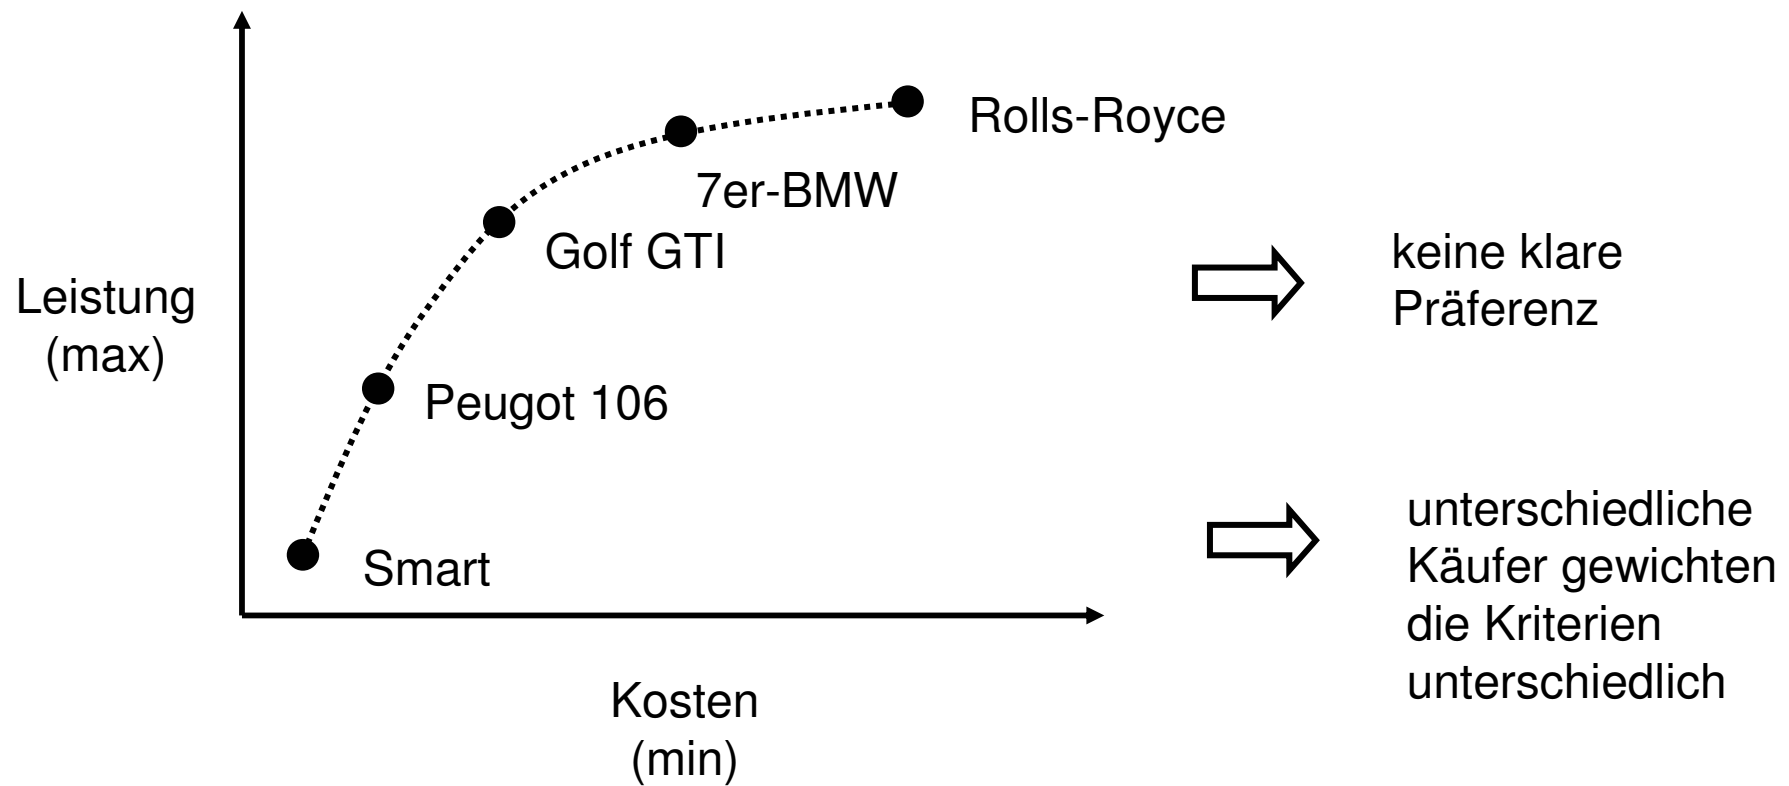
Lernziele dieser Vorlesung

- Entwicklung des Grundverständnisses für mehrkriterielle Optimierungsprobleme
- Erlernen der Pareto-Begrifflichkeiten
- Verständnis der klassischen Optimierungsmethoden
- Erlernen des ersten evolutionären mehrkriteriellen Verfahrens





Einleitung

- Bisher nur Optimierungen mit einem Zielkriterium
- Nun, Zielkriterien mit Zielkonflikten für ein gemeinsames Optimierungsproblem
- Beispiele:
 - Autokauf (Preis versus Leistung)
 - Motorenleistung (Hubraum versus Verbrauch)
 - Prüfungen (Arbeitszeit versus Freizeit)

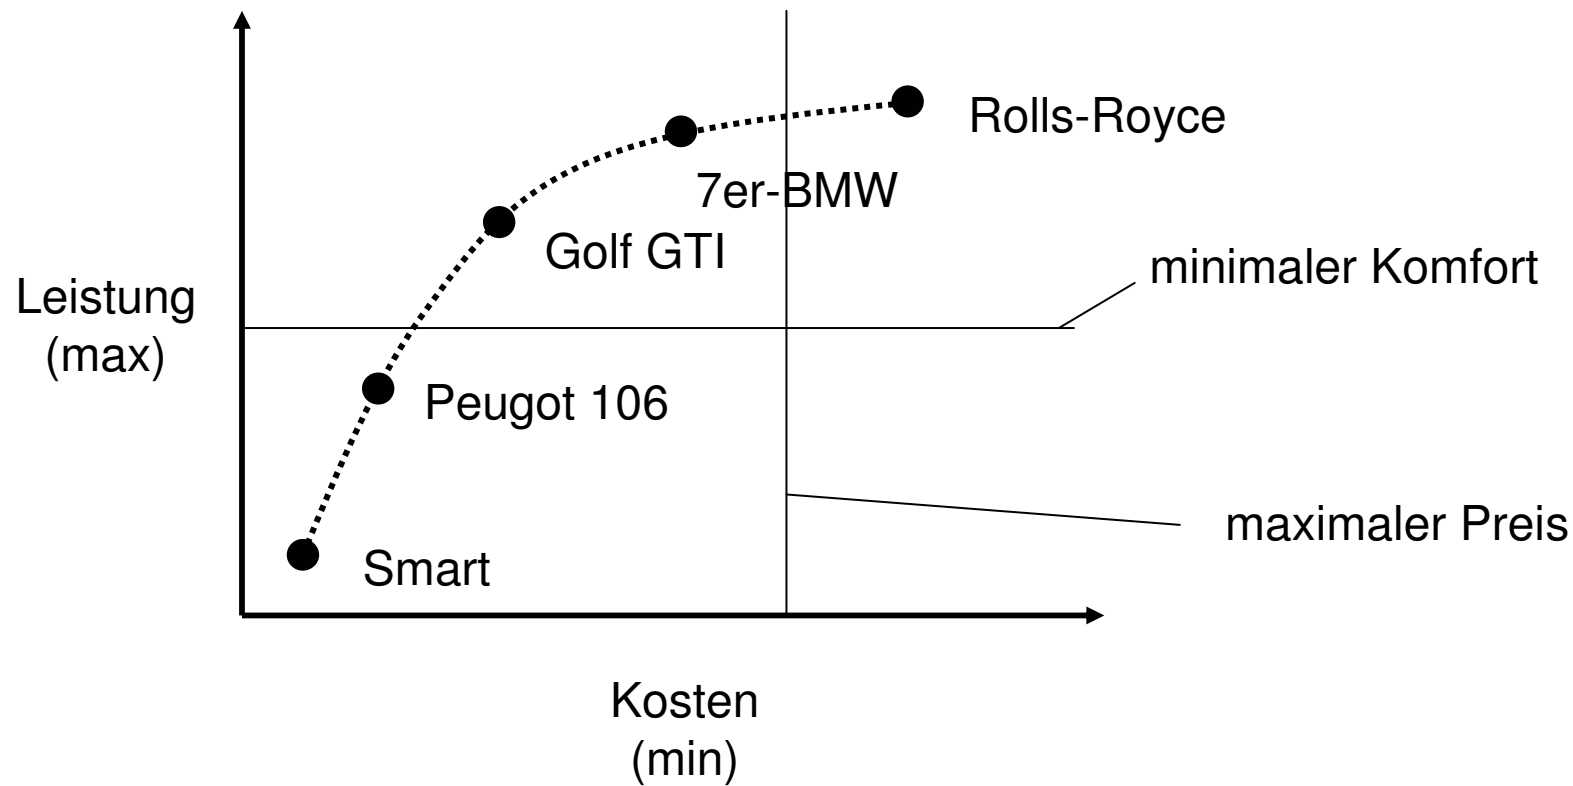
Beispiel Autokauf



Darstellung unterschiedlicher Optimierungskombinationen

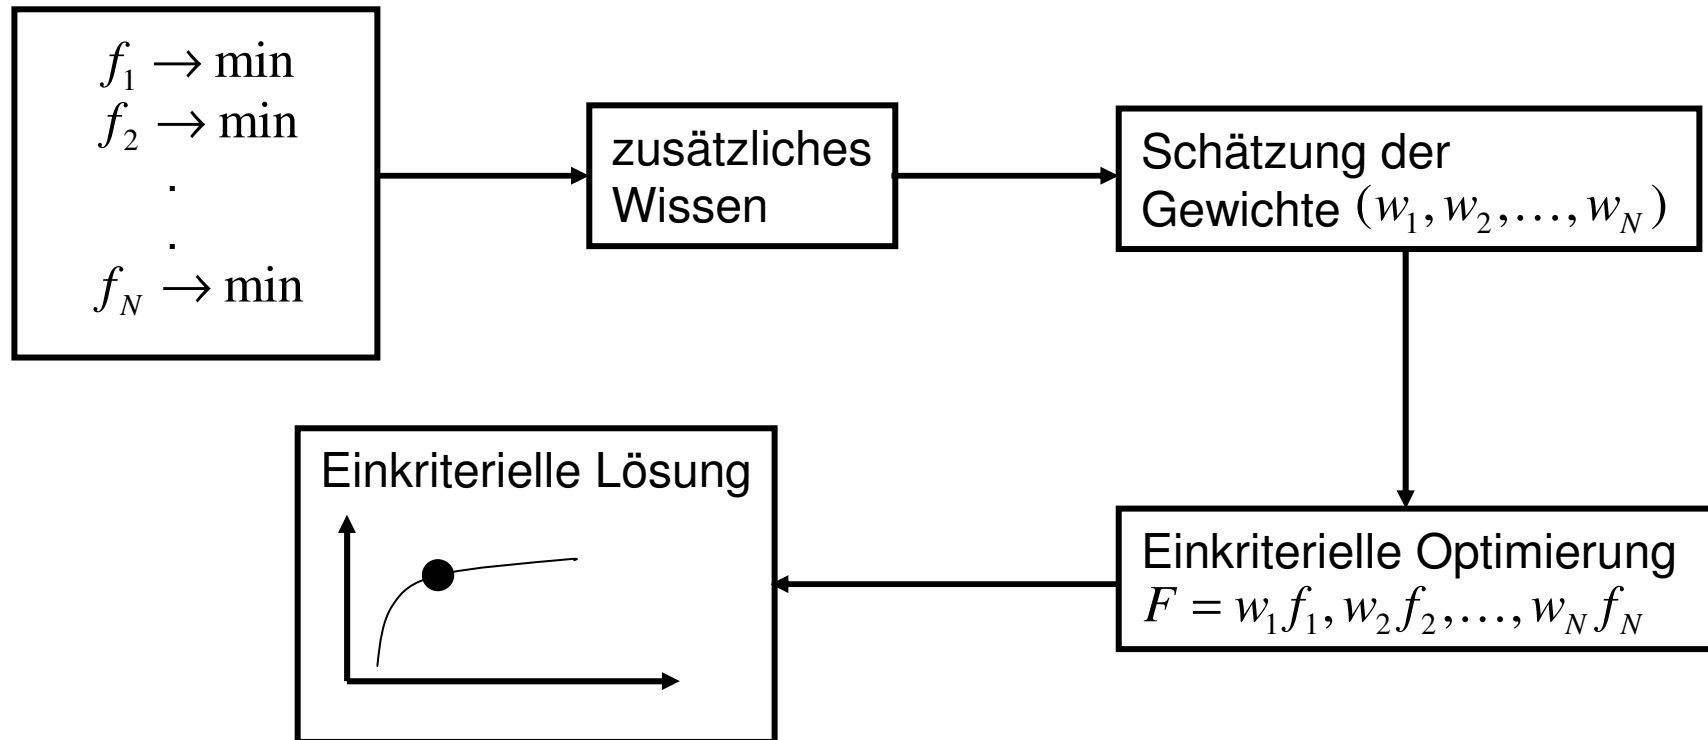


In realen Problemen - Nebenbedingungen

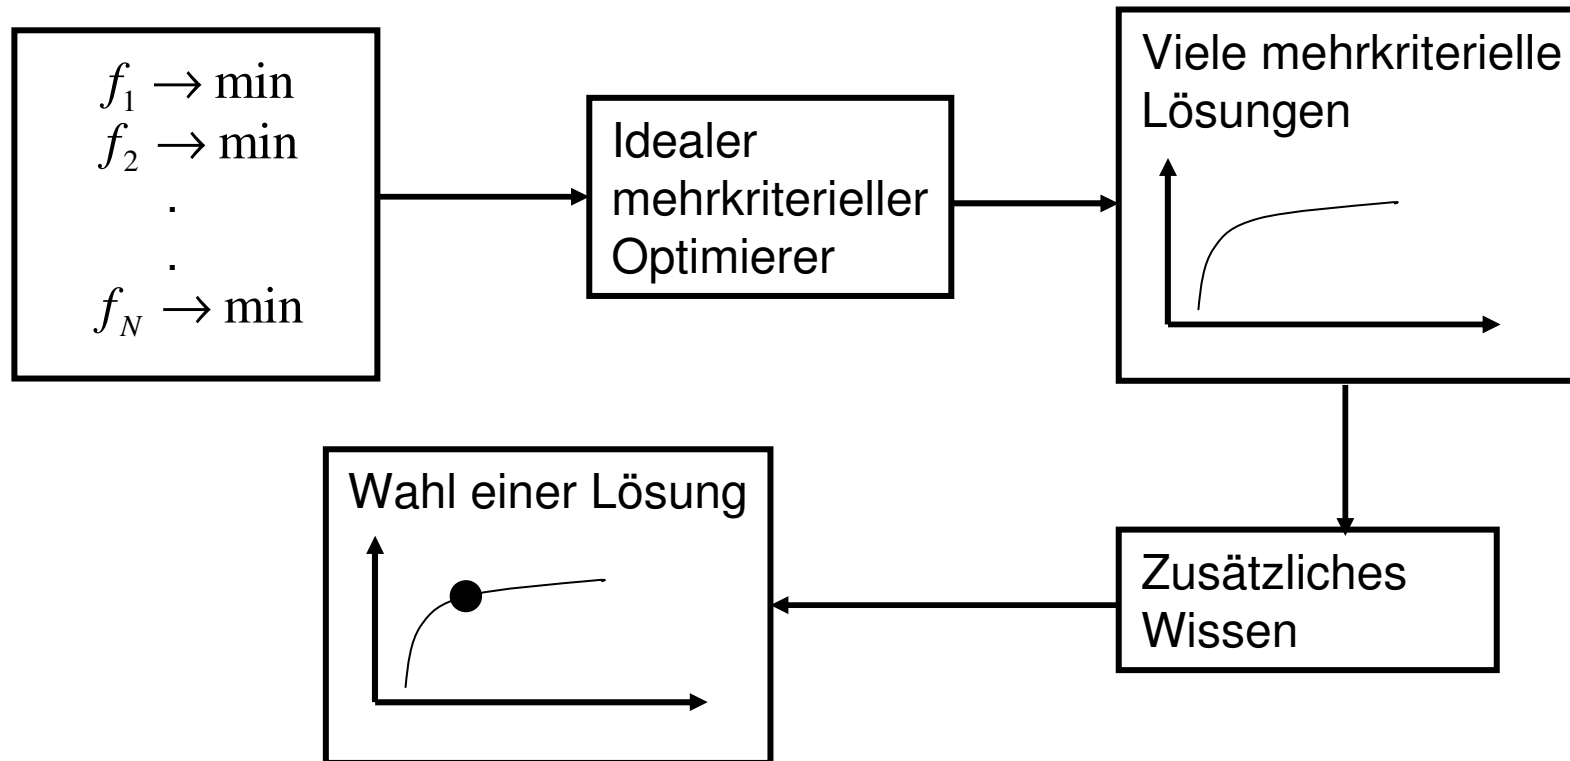


Aber: Was wird dazwischen präferiert?

Methode 1: Präferenz-basierte Mehrkriterielle Optimierung



Methode 2: Ideale Mehrkriterielle Optimierung



Vergleich

Präferenzbasierte mehrkriterielle Optimierung

- Einkriterielle Lösung, die in Iterationen verbessert wird (klassische Verfahren)




Zur Erzeugung der Menge der Lösungen mit Zielkonflikt sind viele parameterisierte Lösung

9 nötig

Ideale mehrkriterielle Optimierung

- Ziel: viele Lösungen mit Zielkonflikt



Evolutionär geeignet, da pro Generation viele individuelle Lösungen existieren

Mehrkriterielle Optimierung – formaler Ansatz

$$f_m(x) \rightarrow \min, \quad m = 1, 2, \dots, M$$

mit den Nebenbedingungen:

$$g_j(x) \geq 0, \quad j = 1, 2, \dots, J;$$

$$h_k(x) = 0, \quad k = 1, 2, \dots, K;$$

$$x_i^{(U)} \leq x_i \leq x_i^{(O)}, \quad i = 1, 2, \dots, n;$$

Konzept der Dominanz (Annahme: Zielminimierung)

Eine Lösung $x^{(1)}$ wird als **dominant** bezeichnet gegenüber einer Lösung $x^{(2)}$ wenn beide Bedingungen erfüllt sind:

- 1) Die Lösung $x^{(1)}$ ist nicht schlechter als $x^{(2)}$ in allen Zielfunktionen, oder

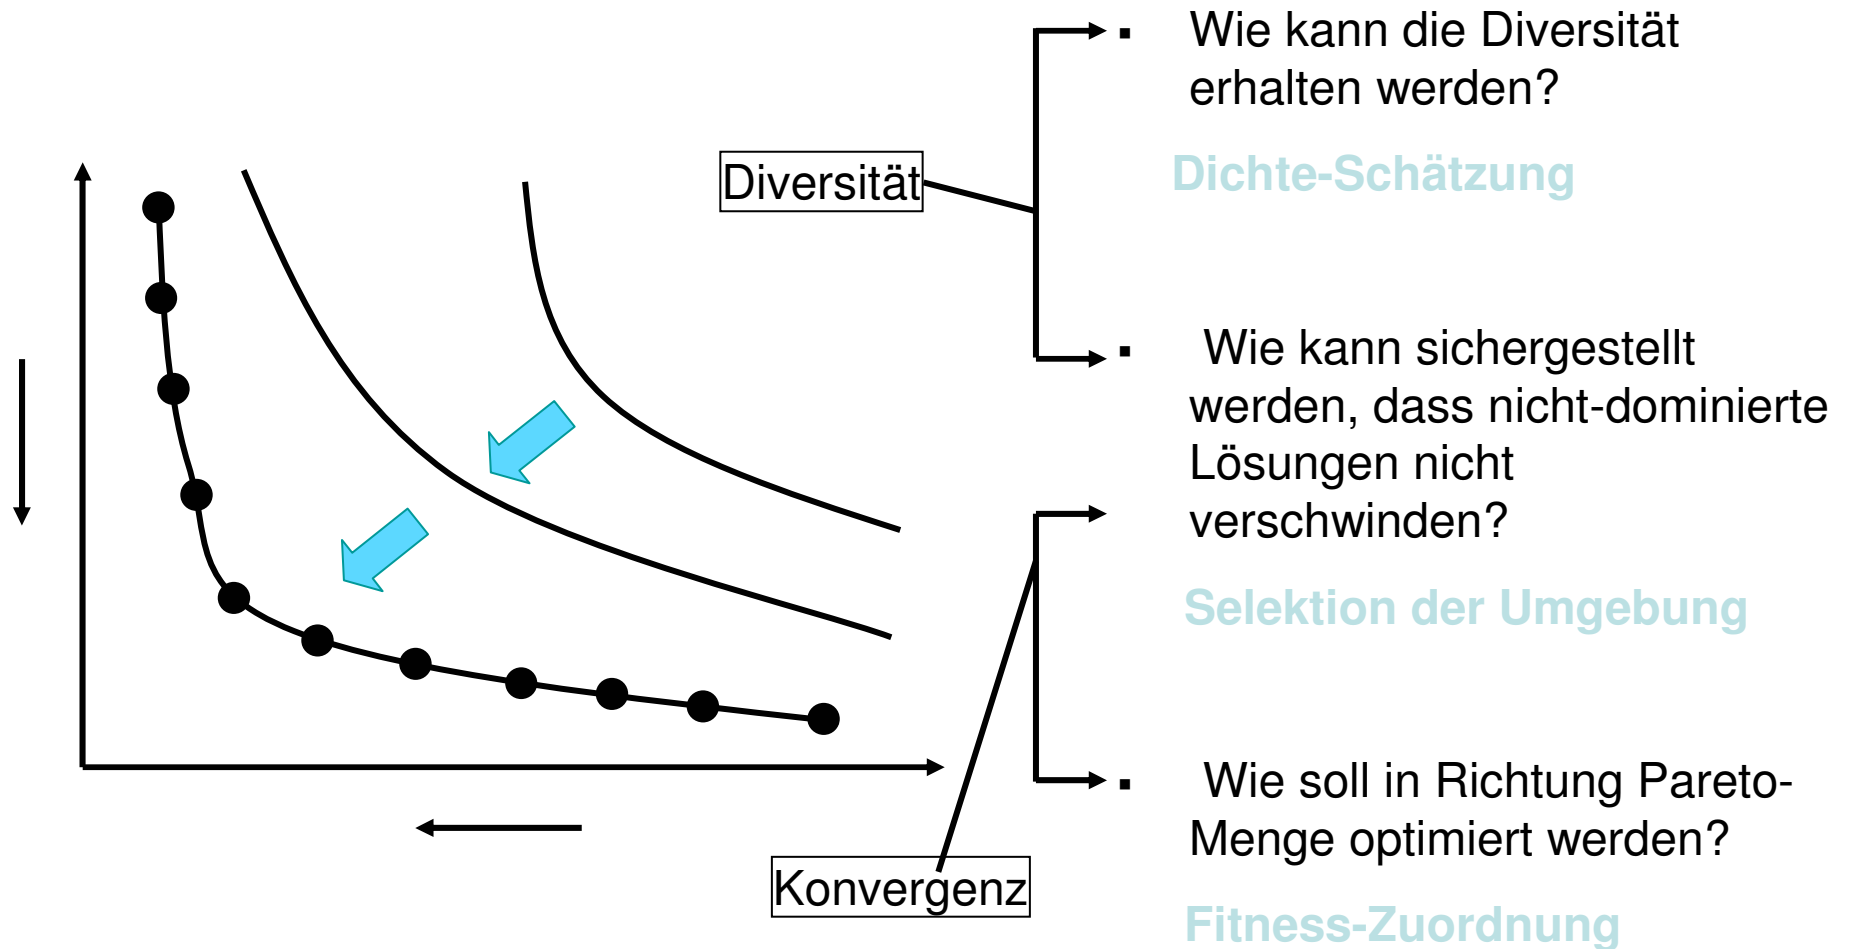
$$f_j(x^{(1)}) \preceq f_j(x^{(2)}) \text{ für alle } j = 1, 2, \dots, M$$

- 2) Die Lösung $x^{(1)}$ ist strikt besser als $x^{(2)}$ bezüglich mindestens einer Zielfunktion, oder

$$f_j(x^{(1)}) \prec f_j(x^{(2)}) \text{ für mindestens eins } j \in [1, M]$$


Das Ermitteln der nicht-dominierten Menge mit M-Funktionen und N-Variablen benötigt: $O(N(\log N)^{M-2})$

Ziele der mehrkriteriellen Optimierung



Paretodominanz

- Paretoäquivalenz – Paretodominanz



Multi-Objective Optimization

Formal Problem Definition

- **Pareto Optimalität:** Ein Entscheidungsvektor $\vec{x} \in X_f$ ist *non-dominated* bezüglich der Menge $A \subseteq X_f$, wenn $\nexists \vec{a} \in A : \vec{a} \prec_p \vec{x}$. Des Weiteren ist \vec{x} Pareto optimal wenn \vec{x} nicht dominiert wird von X_f .
- **Nicht dominierte Menge und Front:** Sei $A \subseteq X_f$. Die Funktion $nd(A)$ ergibt die nicht-dominierte Untermenge von A:


$$nd(A) = \{\vec{x} \in A \mid \nexists \vec{x}' \in A \text{ with } \vec{x}' \prec_p \vec{x}\}$$

Die zugehörigen Objektvektoren $\vec{f}(X_p)$ bilden die nicht-dominierte Front bezüglich A. Des Weiteren wird die Menge $X_p = nd(X_f)$ die **Pareto optimale Menge** und die Menge $\vec{f}(nd(X_f))$ die **Pareto-Front** genannt.


Übung

- Welche Aussage ist richtig:
 - Die Pareto-Front beschreibt alle Entscheidungsvektoren, die von anderen Lösungen nicht dominiert werden.
 - Die Pareto-Menge beschreibt alle Entscheidungsvektoren, die von anderen Lösungen nicht dominiert werden.


Pareto-optimale Lösungen (min-min)




Pareto-optimale Lösungen (min-max)



Pareto-optimale Lösungen (max-min)



Pareto-optimale Lösungen (max-max)



Übung

1. Gegeben seien folgende Nutzenfunktionen

Minimiere $(-x_1^3)$

Maximiere $\exp(x_1^2)$

Wenn beide Nutzenfunktionen optimiert werden, kann es dabei Pareto-optimale Lösungen geben? Begründen Sie.

Übung

2. Überprüfen Sie ob die erste Lösung die zweite dominiert.

a) (min, min) : $f^{(1)} = (1,2; 3,5)^T$, $f^{(2)} = (1,5; 3,0)^T$

b) (min, max, min) : $f^{(1)} = (10,5; 1,5; -10,0)^T$, $f^{(2)} = (5,0; 0,5; -12)^T$

c) (min, min, min) : $f^{(1)} = (10,5; 1,5; -10,0)^T$, $f^{(2)} = (5,0; 0,5; -12)^T$

d) (max, max, min) : $f^{(1)} = (10,5; 1,5; -10,0)^T$, $f^{(2)} = (5,0; 0,5; -12)^T$

e) (max, max, max) : $f^{(1)} = (10,5; 1,5; -10,0)^T$, $f^{(2)} = (5,0; 0,5; -12)^T$

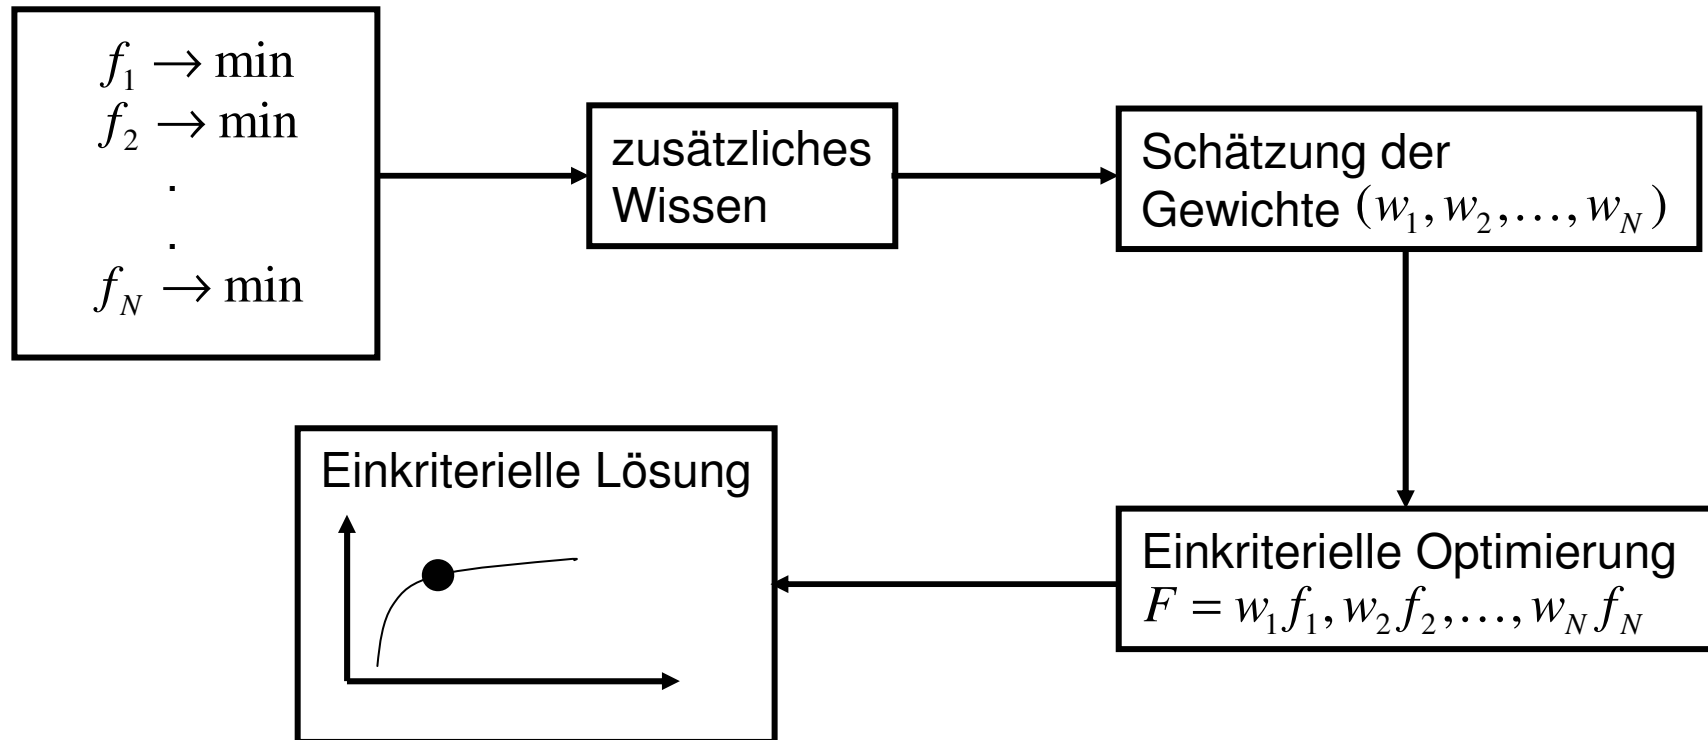
f) (min, max, max) : $f^{(1)} = (10,5; 1,5; -10,0)^T$, $f^{(2)} = (5,0; 0,5; -12)^T$

Klassische Methoden

Klassische Verfahren der mehrkriteriellen Optimierung:

- Gewichtete Summenmethode
- epsilon-bedingte Methode
- Gewichtete Metrik-Methode
- Werte-Funktion Methode
- Benson's Methode
- Ziel-Programmierung Methode

Methode 1: Präferenz-basierte Mehrkriterielle Optimierung



Gewichtete Summenmethode

- Gebräuchlichste klassische Methode
- Gewichte : definiert vom Anwender
- Maximiere: $F_m(x) = \sum_{m=1}^M w_m \cdot f_m(x)$
- mit: $\sum_{m=1}^M w_i = 1, w_i \geq 0$
 $g_j(x) \geq 0, j = 1, 2 \dots J;$
 $h_k(x) = 0, k = 1, 2 \dots K;$
 $x_i^{(L)} \leq x_i \leq x_i^{(U)}, i = 1, 2 \dots n;$
- Vorteile:
 - Einfach zu nutzen
 - Für konvexe Fronten nachweislich
- Nachteile:
 - Gewichte sind sehr sensitiv
 - Unterschiedliche Gewichte führen nicht notwendiger Weise zu unterschiedlichen Lösungen

Übung


- Maximiere: $F_m(x) = \sum_{m=1}^M w_m \cdot f_m(x)$
- mit: $\sum_{m=1}^M w_i = 1, w_i \geq 0$
 $g_j(x) \geq 0, j = 1, 2 \dots J;$
 $h_k(x) = 0, k = 1, 2 \dots K;$
 $x_i^{(L)} \leq x_i \leq x_i^{(U)}, i = 1, 2 \dots n;$
- Was muss variiert werden, um eine Pareto-Front zu erzeugen?

epsilon-bedingte Methode

- Minimiere: $f_\mu(x)$,
- mit:
 - $f_m(x) \leq \varepsilon_m, \quad m = 1, 2, \dots, M \text{ und } m \neq \mu$
 - $g_j(x) \geq 0, \quad j = 1, 2, \dots, J;$
 - $h_k(x) = 0, \quad k = 1, 2, \dots, K;$
 - $x_i^{(L)} \leq x_i \leq x_i^{(U)}, \quad i = 1, 2, \dots, n;$
- Vorteile:
 - Methode funktioniert für konvexe und nicht-konvexe Suchräume
- Nachteile:
 - Für alle Nutzenfunktionen sind gute Informationen notwendig
 - Lösung hängt sehr vom gewählten epsilon ab

Gewichtete Metrik Methode


- Minimiere: $l_p(x) = \left(\sum_{m=1}^M w_m |f_m(x) - z_m^*|^p \right)^{1/p}$,
- mit: z^* – ideale Lösung
 $g_j(x) \geq 0, \quad j = 1, 2 \dots J;$
 $h_k(x) = 0, \quad k = 1, 2 \dots K;$
 $x_i^{(L)} \leq x_i \leq x_i^{(U)}, \quad i = 1, 2 \dots n;$
- Sonderform gewichtet Tchebycheff: $l_\infty = \max_{m=1}^M (w_m |f_m(x) - z_m^*|)$
- Vorteile:
 - gewichtetes Tchebycheff Problem findet alle Pareto-optimalen Lösungen, wenn z^* ein utopian Vector ist (Miettinen 1999)
- Nachteile:
 - Werte können sich in Größenordnungen unterscheiden. Daher ist eine Normalisierung sinnvoll, die zusätzliches Wissen braucht.
 - Die ideale Lösung z^* muss bekannt sein.



Benson's Methode

$$\max \sum_{m=1}^M \max(0, (z_m^{\circ} - f_m(x)))$$

$$\text{mit } f_m(x) \leq z_m^{\circ}$$



- „Vergrößere den Abstand zu einer schlechten Lösung“ z_m°
- Problem: Optimierungsmethoden sind schwer nutzbar, da die Optimierungsfunktion nicht differenzierbar ist

Werte-Funktion Methode

$$\max U(f(x)); U : R^M \rightarrow R$$

$$f(x) = (f_1(x), f_2(x), \dots, f_M(x))^T$$

- Probleme:
 - Werte-Funktion ist schwer zu bestimmen
 - Werte-Funktion muss überall im gültigen Lösungsraum definiert sein.

Ziel-Programmierungs-Methode

- Für jede Zielfunktion wird ein Ziel definiert

$$\text{Ziel } (f(x) = t)$$

- Oft Übersetzung in: $f(x) - p + n = t$

positive Abweichung

negative Abweichung

- Resultierendes Ziel: $\min(p + n)$
- z.B. gewichtete Zielprogrammierung:

$$\min \sum_{m=1}^M (\alpha_m p_m + \beta_m n_m)$$


$$\text{mit } f_m(x) - p_m + n_m = t, m = 1, 2, \dots, M$$

Übung

- Was kann mittels alpha und beta realisiert werden?

Probleme der klassischen Ansätze

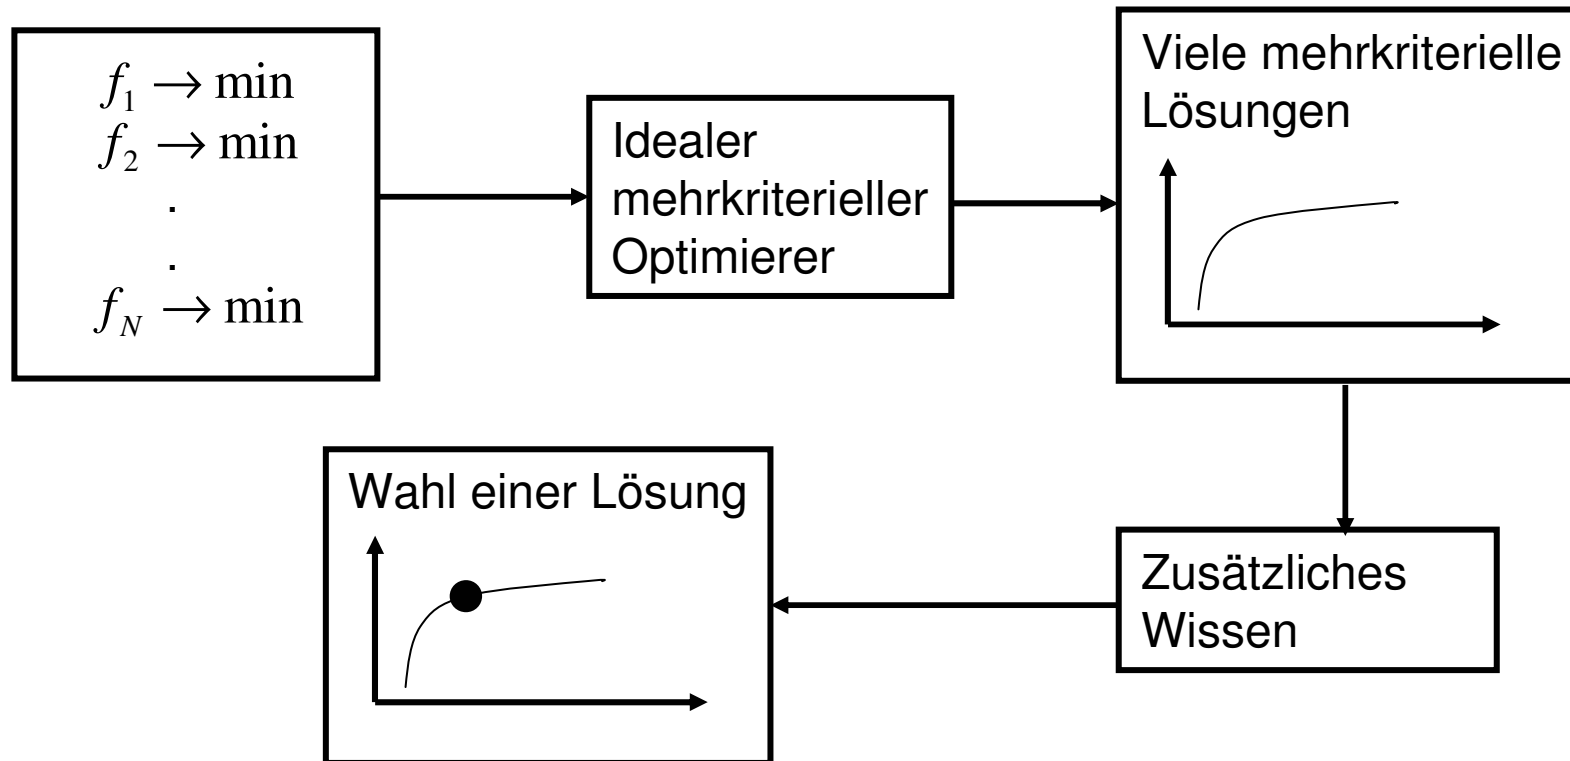
Wie soll die Diversität erhalten werden?



Klassische Methoden

- Vorteile:
 - Konvergenz (hier nicht gezeigt)
 - leicht zu implementieren
- Nachteile:
 - stets Umwandlung eines mehrkriteriellen Problems in ein einkriterielles Problem
 - Parametervariation notwendig um eine Pareto-Front zu erhalten (unterschiedliche Parameter müssten dann zu unterschiedlichen Lösungen führen)

Methode 2: Ideale Mehrkriterielle Optimierung



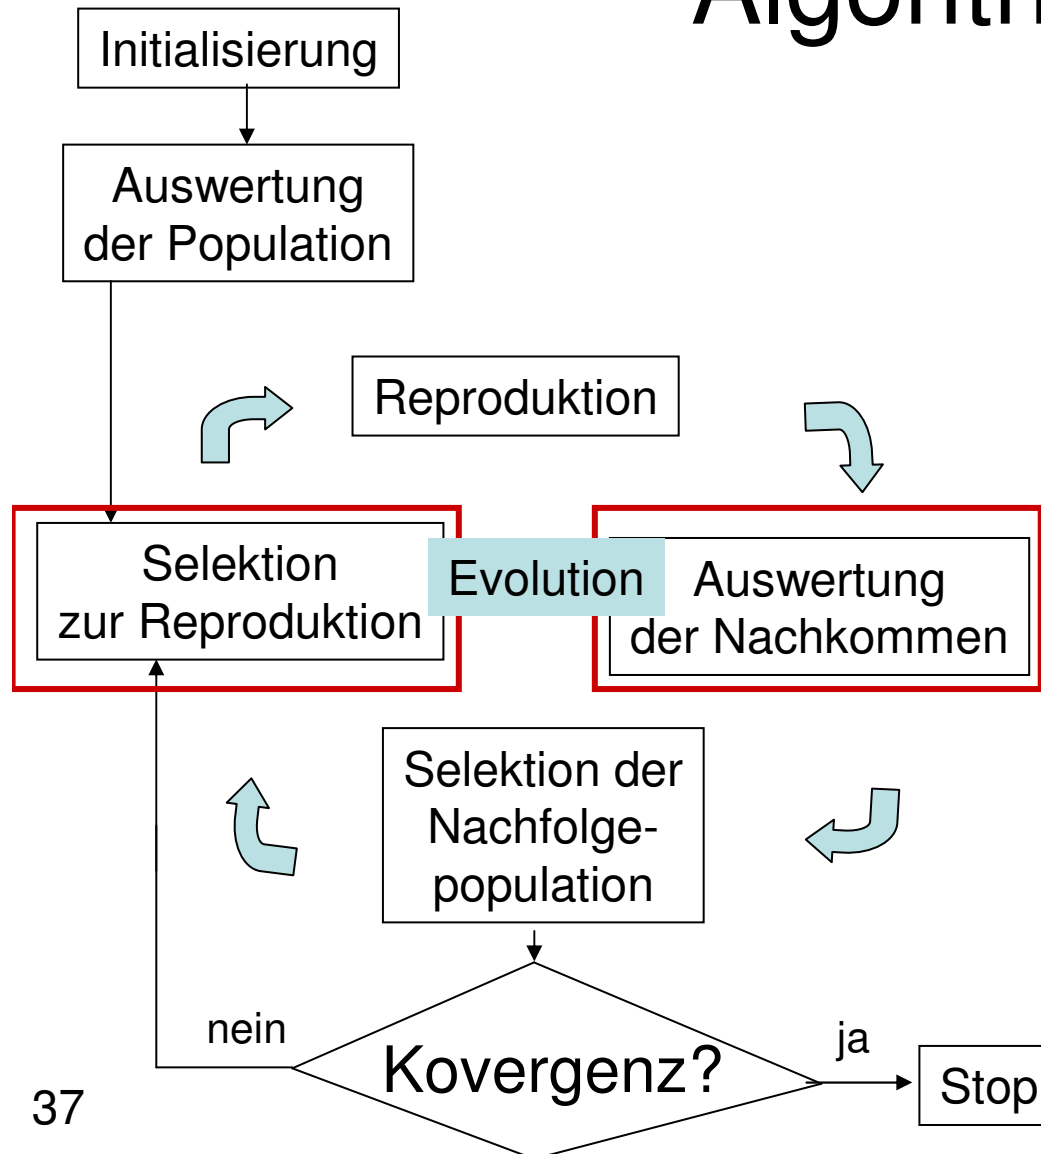
Wesentliche Vorteile mehrkriterieller Evolutionärer Algorithmen

- Pro Generation werden viele Lösungen gefunden
- Kein Bedarf nach idealen Lösungen/Gewichten etc.
- Alle nicht-dominierten Lösungen werden gleich betont
- Methoden zur Erhaltung der Diversität lassen sich besser integrieren
- Algorithmen können an viele verschiedene Probleme angepasst werden

Mehr-kriterielle Evolutionäre Algorithmen (Beispiele)

- Nicht-elitäre Algorithmen
 - Vector Evaluated Genetic Algorithm (VEGA)
 - Non-dominated Sorting Genetic Algorithm (NSGA)
 - Predator-Prey Evolution Strategy
 - sehr viele andere
- Elitäre Algorithmen
 - Elitist Non-dominated Sorting Genetic Algorithm (NSGA-II)
 - Strength Pareto Evolutionary Algorithm (SPEA 2)
 - S metric selection Multi-objective Evolutionary Algorithm (SMS-EMOA)
 - Indicator Based Evolutionary Algorithm (IBEA)
 - viele andere

Allgemeiner evolutionärer Algorithmus



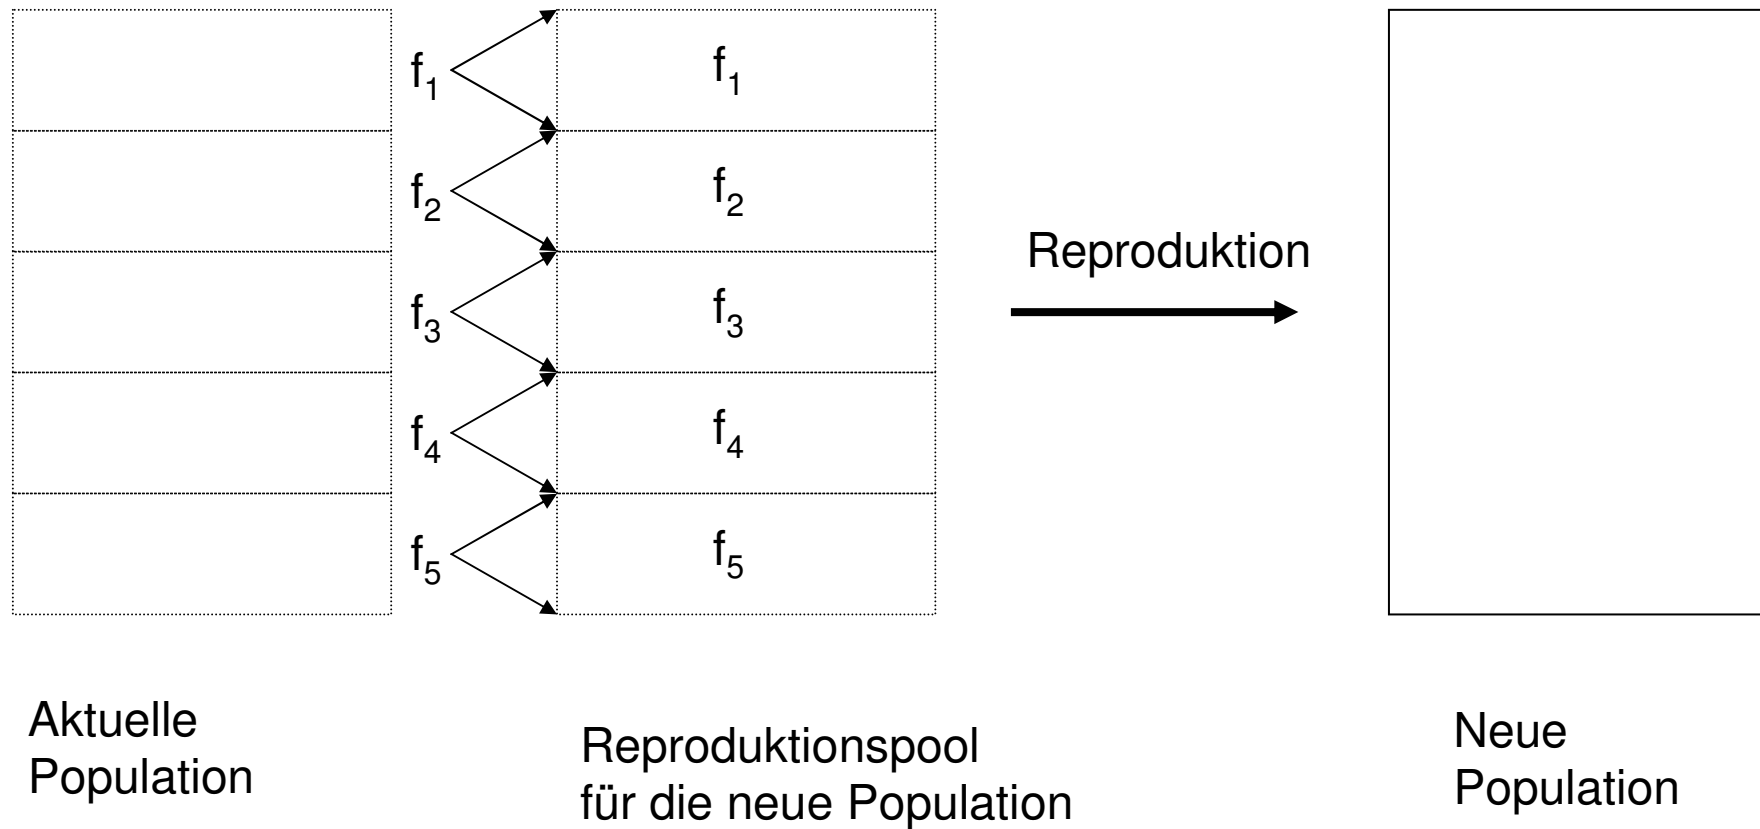
Hier liegen die wesentlichen Änderung. Dies ist im Wesentlichen auch für die meisten anderen mehrkriteriellen EAs so.

Vector Evaluated Genetic Algorithm

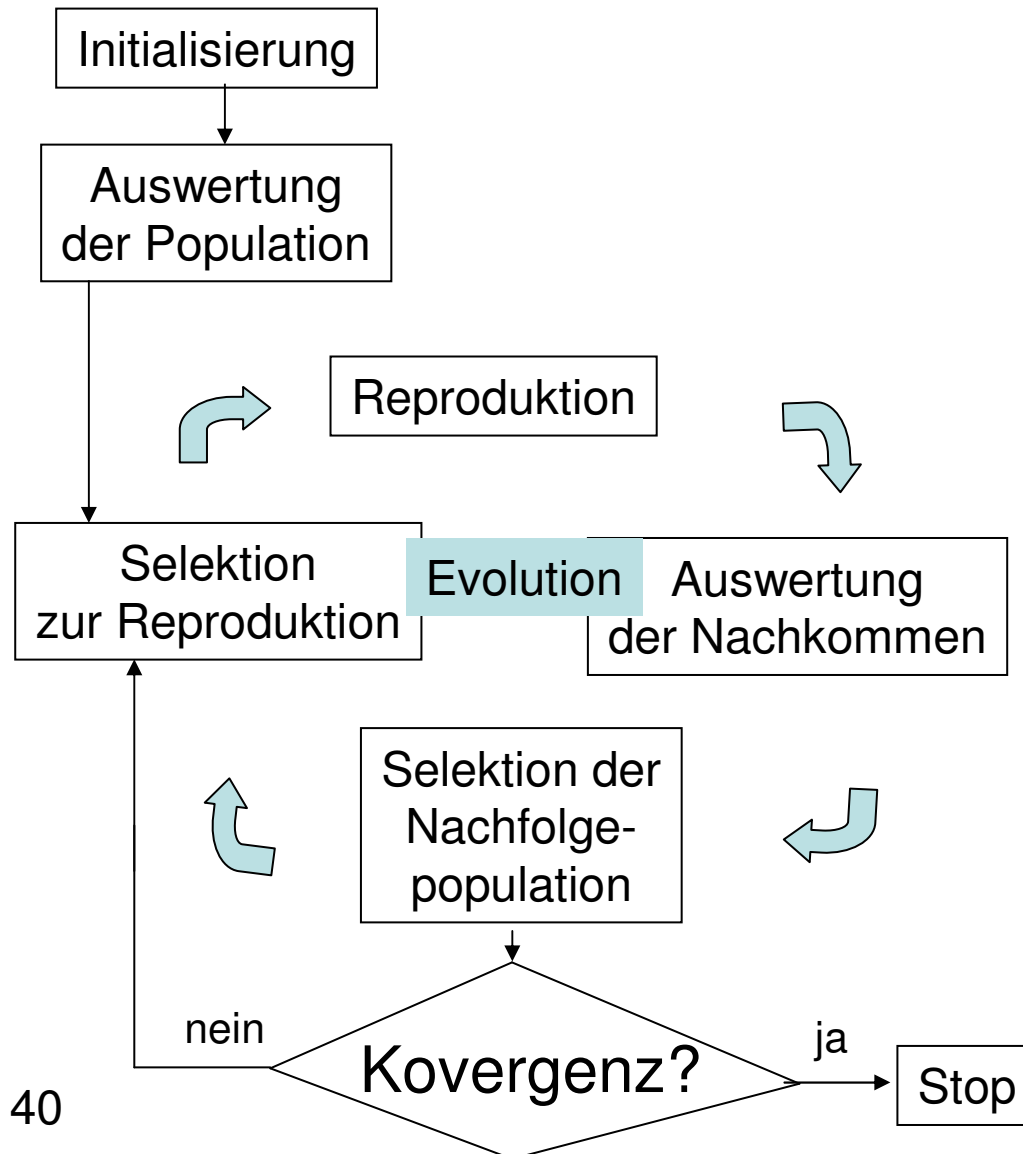
- Erster bekannter mehrkriterieller evolutionärer Algorithmus von Schaffer (1984)
- Nutzung eines Vektors für die verschiedenen Funktionswerte – ein Eintrag pro Funktion
- Extrem einfacher Algorithmus
- Eindeutige Zuweisung einer zufälligen, aber gleich großen Teilmenge der jeweiligen Population zu den jeweiligen Nutzenfunktionen
- Nutzung eines „normalen“ Genetischen Algorithmus“ zur eigentlichen Evolution

VEGA Auswertungsschema

In der Regel sollte die Zuordnung zufällig erfolgen.



Übung



Welcher Teil eines allgemeinen EAs wird bei VEGA verändert?

VEGA Selektion

- N- Anzahl der Individuen; M-Anzahl der Nutzenfunktionen
 - 1) Setze $i = 1$ und $q = N/M$
 - 2) Für alle $j=1+(i-1)*q$ bis $j=i*q$:
 - 1) $F(x^j) = f_i(x^j)$ //wähle für Individuum j die Nutzenfunktion i
 - 3) Führe F-proportionale Selektion aller q Lösungen aus und erstelle den $Pool_i$
 - 4) Wenn $i=M$, gehe zu 5. Sonst $i++$ und 2)
 - 5) Erstelle den Reproduktionspool $P = \bigcup_{i=1}^M P_i$

VEGA Vor- und Nachteile


- Vorteile
 - Einfach und leicht zu implementieren
- Nachteile
 - Viele Lösungen liegen nahe an den optimalen Lösungen der einzelnen Nutzenfunktionen (schlechte Diversität)
 - Rekombinations-operator versagt häufig beim Erstellen von Zwischenlösungen zur Erzeugung der Pareto-Front

Übung

- Das Problem

Minimiere $f(d, h) = c\left(\frac{\pi d^2}{2} + \pi dh\right)$

Maximiere $g_1(d, h) = \frac{\pi d^2 h}{4}$



Variablen $0 < d \leq 32$

$$0 < h \leq 32$$

- Erzeugen Sie die Pareto-Front mit VEGA!
- Nutzen Sie pro Nutzenfunktion 15 zufällig ausgewählte Individuen.
- Nutzen Sie die Rang-basierte Selektion

Vorlesungsplanung

- 21.02.2012: Einkriterielle Evolutionäre Optimierung I (CF)
- 28.02.2012: Einkriterielle Evolutionäre Optimierung II (CF)
- 06.03.2012: Test (1+2), Mehrkriterielle Evolutionäre Optimierung I (CF)
- 13.03.2012: Statistische Lerntheorie I (JP)
- 20.03.2012: Statistische Lerntheorie II (JP)
- 27.03.2012: Test (4+5), Neuronale Netze (JP)
- 10.04.2012: Support Vector Maschinen I (JP)
- 02.05.2012: Mehrkriterielle Evolutionäre Optimierung II (CF)
- 08.05.2012: Genetische Fuzzy Systeme (CF)
- 15.05.2012: Test (3+8+9), Meta-Heuristiken (ACO, PSO) (CF)
- 22.05.2012: Simulated Annealing und andere Suchmethoden (CF)
- 29.05.2012: Support Vector Maschinen II (JP)
- 05.06.2012: Test (6+7+12), Clustering (JP)
- 12.06.2012: Lernen und Spieltheorie (JP)
- 26.06.2012: 1. Termin mündliche Prüfungen
- 03.07.2012: 2. Termin mündliche Prüfungen

Hausaufgabe

- Beenden Sie bitte alle in der Vorlesung nicht vollständig bearbeiteten Übungen+
- Lesen Sie das paper: „Indicator-Based Selection in Multiobjective Search“ von Eckart Zitzler and Simon Künzli (beide ETH Zürich)