

Maschinelles Lernen

Grundlegende Begriffe

- Überwachtes Lernen
 - Regression
 - Z.B. Schätzen des Benzinverbrauchs eines Autos
 - Klassifikation
 - Z.B. Handschriftenerkennung
- Unüberwachtes Lernen
 - Clustering
 - Z.B. Erkennung eines Kreditkartenbetrugs
- Bestärkendes Lernen („reinforcement learning“)
 - Z.B. Anwendung in der Robotik

Regression

- Gegeben: Features X_i und zugehörige Werte Y_i
- Gesucht: Abbildung $X \rightarrow Y$
- Beispiel: Wie lange brauche ich für meinen Weg zur Arbeit und zum Sportverein?

Klassifikation

- Gegeben: Features X_i und zugehörige Attribute Y_i
- Gesucht: Abbildung $X \rightarrow Y$
- Beispiel: Nach einem Blick auf die Wetterstation, regnet es heute?

Regression: Einfachster Fall

- Keine Features, nur Werte A_i
- Gesucht: eine Schätzung \hat{A} für A
- Beispiele:
 - Anzahl der Regentage im Monat Mai
 - Fahrzeit zur Arbeit in Sekunden
 - Körpergrösse eines erwachsenen Europäers in cm
- Eigentlich gesucht: **Verteilung**

Normalverteilung

- Modell: $A \sim \mathbf{N}(\mu, \sigma^2)$

$$p(A = a) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(a-\mu)^2}{2\sigma^2}}$$

Warum Normalverteilung?

Zentraler Grenzwertsatz: Gegeben unabhängige und identisch verteilte Zufallsvariablen X_1, X_2, X_3, \dots
Wenn Erwartungswert μ und Varianz σ^2 der Verteilung existieren, dann konvergiert

$$\frac{X_1 + X_2 + \dots + X_n - n\mu}{\sqrt{n\sigma^2}}$$

für $n \rightarrow \infty$ gegen die Standard-Normalverteilung $N(0,1)$


Rechnen mit Zufallsvariablen

- Summen
- Erwartungswert
- Varianz
- Diskrete und kontinuierliche Zufallsvariablen
- **Übung: ZGWS simulieren**
- Wer kein `randn` hat: Box-Muller Methode:

$$z = \sqrt{-2 \ln u_1} \cos(2\pi u_2)$$

Herleitung Box-Muller

- X_1 und X_2 seien $N(0,1)$ verteilt
- $X_1^2 + X_2^2$ ist χ^2_2 – verteilt:
 $f(x) = \frac{1}{2} e^{-\frac{1}{2}x}$
- $X_1^2 + X_2^2$ kann durch $-2 \ln u_1$ erzeugt werden
- Die zweidimensionale Normalverteilung ist rotationsinvariant



Der ZGWS in der Simulation

```
for i=1:100
    A = rand(i,10000)-.5;
    m(i) = mean((sum(A,1)/sqrt(i)));
    y(i) = mean((sum(A,1)/sqrt(i)).^2);
end
plot(m);
plot(y);
hist(sum(A,1)/sqrt(i),100);
```

Starkes Gesetz der Grossen Zahlen

Gegeben unabhängige und identisch verteilte Zufallsvariablen X_1, X_2, X_3, \dots . Wenn Erwartungswert μ und Varianz σ^2 der Verteilung existieren, dann konvergiert

$$\frac{X_1 + X_2 + \dots + X_n}{n}$$

für $n \rightarrow \infty$ *fast sicher* gegen den Mittelwert μ

Übung

- Starkes Gesetz der grossen Zahlen simulieren
- Was sind die Unterschiede zum ZGWS?

Schätzung einer Verteilung

- Keine Features, nur Werte A_i
- Gesucht: eine Schätzung \hat{A} für A
- Modell: $A \sim N(\mu, \sigma^2)$
- $p(A_{i:i=1\dots n}) \sim \exp\{ - [\Sigma(A_i - \mu)^2] / (2\sigma^2) \}$
- Welches Paar (μ, σ^2) ist am besten?
- Für die Daten $A_{i:i=1\dots n}$, welches Paar (μ, σ^2) ist am wahrscheinlichsten?
- Umgekehrt: für welches Paar (μ, σ^2) sind die Daten $A_{i:i=1\dots n}$ am wahrscheinlichsten?

Maximum-Likelihood Schätzer

- $\exp\{ - [\Sigma(A_i - \mu)^2] / (2\sigma^2) \} \sim p(A_{i:i=1\dots n}) = \max!$

$$\Leftrightarrow [\Sigma(A_i - \mu)^2] / (2\sigma^2) \sim -\log p(A_{i:i=1\dots n}) = \min!$$

$$\Leftrightarrow \Sigma(A_i - \mu)^2 = \min!$$

$$\Leftrightarrow d/d\mu \Sigma(A_i - \mu)^2 = 0$$

$$\Leftrightarrow \Sigma(A_i - \mu) = 0$$

$$\Leftrightarrow \mu = (\Sigma A_i) / n = \text{Mittelwert}$$

Bemerkung: σ^2 nicht länger relevant!

ML Schätzer

- Ein Schätzer \hat{A} ist ein ML Schätzer für eine Variable A unter Beobachtungen X_1, X_2, X_3, \dots , falls

$$p(X_1, X_2, X_3, \dots | \hat{A}) = \max_A p(X_1, X_2, X_3, \dots | A)$$

Erwartungstreuer Schätzer

- Ein Schätzer \hat{A} ist ein erwartungstreuer Schätzer (**unbiased**) für einen Parameter A unter Beobachtungen X_1, X_2, X_3, \dots , falls

$$\mathbf{E}\left(\hat{A}(X_1, X_2, X_3, \dots)\right) = A$$

Der Mittelwertschätzer

- Behauptung: Der Mittelwertschätzer $\mu = (\sum A_i) / n$ ist erwartungstreu.
- Beweis:

$$\begin{aligned} \mathbf{E} [(\sum A_i) / n] &= (\sum \mathbf{E} A_i) / n \\ &= (\sum \mathbf{E} A) / n \\ &= \mathbf{E} A \\ &= \mu. \end{aligned}$$

Übung: Taxiproblem

In einer Stadt gibt es N Taxis, die mit fortlaufenden Nummern $1 \dots N$ gekennzeichnet sind. Wir wollen N schätzen. Dafür setzen wir uns an eine Strassenkreuzung und notieren die Nummern der vorbeifahrenden Taxis.

Am Abend haben wir folgende Nummer notiert:

5, 7, 7, 7, 14, 84, 99, 125, 125, 126, 230, 281, 399, 412

Wie können wir N schätzen?

Ist die Schätzung ML?

Ist die Schätzung erwartungstreu?

Taxiproblem: ML Schätzer

- $\hat{N} = \max(n_i)$
- Das ist ML, denn
- Für alle $N < \max(n_i)$ gilt $P(n_{i:i=1\dots m} | N) = 0$
- Für alle $N > \max(n_i)$ gilt
$$\begin{aligned}P(n_{i:i=1\dots m} | N) &= 1 - [1 - N^{-1}]^m \\&< 1 - [1 - \max(n_i)^{-1}]^m \\&= P(n_{i:i=1\dots m} | \hat{N})\end{aligned}$$
- Dieser Schätzer ist nicht besonders gut, da er N systematisch unterschätzt!

Taxiproblem: Erwartungstreuer Schätzer

- $\hat{N} = \max(n_i) + \min(n_i) - 1$
- Erwartungstreu, denn

$$\begin{aligned} E\hat{N} &= E[\max(n_i) + \min(n_i) - 1] \\ &= E[N - (N - \max(n_i)) + \min(n_i) - 1] \\ &= N - E(N - \max(n_i)) + E(\min(n_i) - 1) \\ &= N \end{aligned}$$

Übung

- Wir simulieren das Taxiproblem
 - Wie verhält sich der ML Schätzer?
 - Wie verhält sich der erwartungstreue Schätzer?
 - Können wir noch einen Schätzer mit besseren Eigenschaften finden?

Schätzung der Varianz einer Normalverteilung

- X_i sei $N(\mu, \sigma^2)$
- Fall 1: μ bekannt
 - Dann ist $s^2 = [\sum (X_i - \mu)^2]/n$ ein ML Schätzer
 - s^2 ist auch erwartungstreu
 - Beweis: Übung / Hausaufgabe
- Fall 2: μ unbekannt, setze $m = [\sum X_i]/n$
 - $s^2 = [\sum (X_i - m)^2]/n$ ist ein ML Schätzer
 - s^2 ist nicht erwartungstreu
 - $s_{-1}^2 = [\sum (X_i - m)^2]/(n-1)$ ist erwartungstreu

s^2 ist ML

- $p(X_{1:n}|\mu, \sigma^2) \sim \sigma^{-n} \exp[-\Sigma(X_i - \mu)^2 / (2\sigma^2)]$
- m ist ML für μ unabhängig von σ^2
- $2 \log p(X_{1:n}|\sigma^2) \sim -n \log \sigma - \Sigma(X_i - \mu)^2 / (2\sigma^2)$
- Maximum: Ableitung nach σ muss 0 sein:
- $\sigma^{-1} = \Sigma(X_i - \mu)^2 / (n\sigma^3)$
- $\sigma^2 = s^2$

s_{-1}^2 ist erwartungstreu

- Z.Z.: $\sigma^2 = \mathbf{E} \Sigma (X_i - m)^2 / (n-1)$
- Können annehmen: $\mathbf{E} X_i = 0$

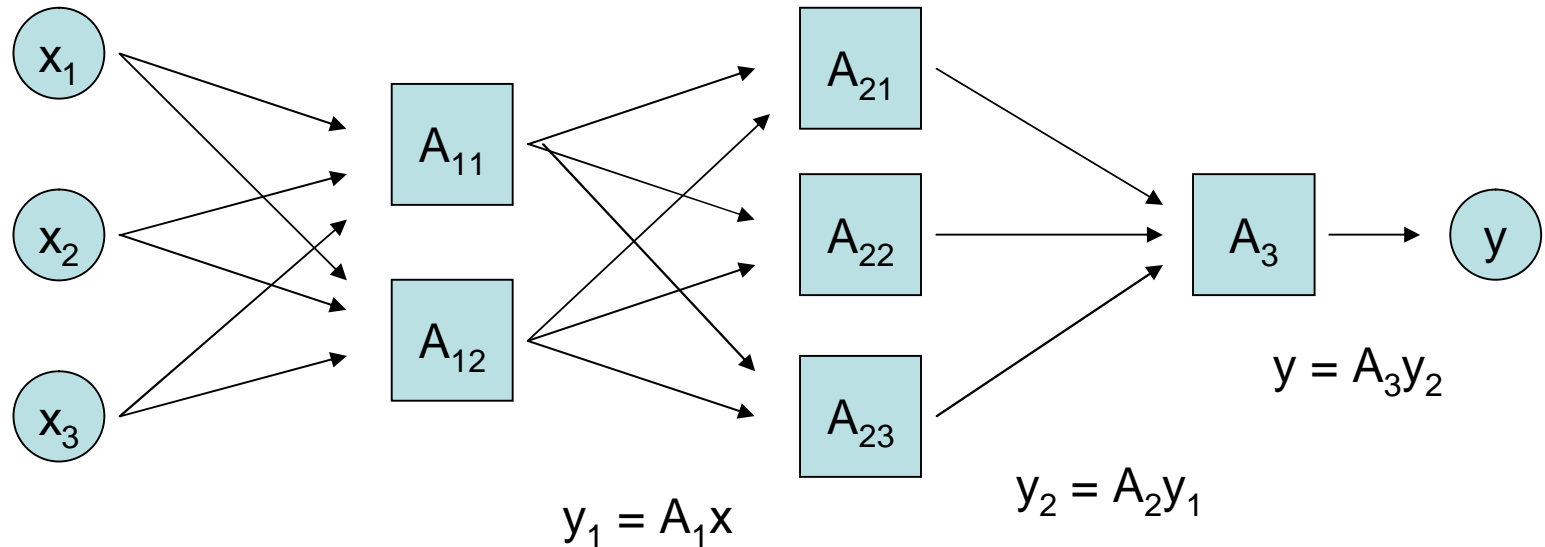
$$\begin{aligned} \Leftrightarrow (n-1)\sigma^2 &= \Sigma \mathbf{E} (X_i - m)^2 \\ &= \Sigma \mathbf{E} [(n-1)/n X_i]^2 + (n-1) \mathbf{E} [X_i/n]^2 \\ &= (n-1)^2/n \sigma^2 + (n-1)/n \sigma^2 \\ &= (n-1)\sigma^2 \end{aligned}$$




Lineare Regression

- Modell: $Y = bX$
- ML-Schätzer für b :
- $(Y - bX)^T(Y - bX) = \min!$
- Ableitung nach b (Gradient):
- $0 = 2X^T X b - 2X^T Y$
- $b = (X^T X)^{-1} X^T Y$

Lineares Neuronales Netz



=



Übung

- Gegeben sind folgende Trainingsdaten
- Aufgabe: trainiere ein entsprechendes Neuronales Netz

X_1	X_2	Y
0.9	3.8	-1.1
1.9	2.4	1.8
3.1	3.6	3.6
0	1.8	-0.7
1.8	3.2	0.9
3.2	2.5	5.3
3.0	3.7	3.7

Lösung

- $X \setminus Y = [2.1176; -0.7706]$
- $[X \text{ ones}(7,1)] \setminus Y = [2.1137; -1.0376; 0.8591]$
- Wahre Koeffizienten = $[2; -1; 1]$

Übung

Schätzung der Anzahl Fische in einem Teich

In einem Teich befinden sich N (unbekannt) Fische. Wir schätzen sie wie folgt: Wir fangen M Fische, markieren sie, und lassen sie wieder frei. Dann warten wir etwas und fangen dann n Fische und zählen, wie viele davon markiert sind (m). Jetzt schätzen wir $\hat{N} = M * n / m$.

- Zeigen Sie: der Schätzer ist ML
- Der Schätzer ist nicht erwartungstreu.

Übung

- Gegeben sind folgende Trainingsdaten
- Aufgabe: trainiere ein quadratisches Regressionsmodell (Ansatz: $y = ax^2 + bx + c$)
- Ist das eine lineare Regression? Warum?

X	Y
0	0
1	0
2	1
3	2
4	5
5	9