

Mehrkriterielle Optimierung

10.4.2012

Carsten Franke

Mehr-kriterielle Evolutionäre Algorithmen (Beispiele)

- Nicht-elitäre Algorithmen
 - Vector Evaluated Genetic Algorithm (VEGA)
 - Non-dominated Sorting Genetic Algorithm (NSGA)
 - Predator-Prey Evolution Strategy
 - sehr viele andere
- Elitäre Algorithmen
 - Elitist Non-dominated Sorting Genetic Algorithm (NSGA-II)
 - Strength Pareto Evolutionary Algorithm (SPEA 2)
 - S metric selection Multi-objective Evolutionary Algorithm (SMS-EMOA)
 - Indicator Based Evolutionary Algorithm (IBEA)
 - viele andere

Non-Dominated Sorting Genetic Algorithm (NSGA)

- Publiziert 1994 von Srinivas und Deb
- Häufigster nicht-elitärer mehrkriterieller Evolutionärer Algorithmus
- Diversität wird verbessert durch ein „Teilungsschema“ benachbarter Lösungen

NSGA - Algorithmus

Algorithm 3.4 Non-Dominated Sorting Genetic Algorithm (NSGA).

$P_{0,\mu} \leftarrow \text{initialization}, P_{0,\mu} \in \mathcal{M}_\mu(\mathbb{I});$
for ($i = 1$ to k) do
$P_{0,\mu} \leftarrow \text{evaluate objective function } f_i;$
end for
$P_{0,\mu} \leftarrow \text{NSGA fitness assignment \{See Algorithm 3.5\}};$
$t \leftarrow 0;$
for ($t = 0$ to (Number of Generations - 1)) do
$P'_{t,\lambda} \leftarrow \text{fitness proportional selection}(P_{t,\mu}), P'_{t,\lambda} \in \mathcal{M}_\lambda(\mathbb{I});$
$P''_{t,\lambda} \leftarrow \text{two point mutation of strategy parameters}(P'_{t,\lambda}), P''_{t,\lambda} \in \mathcal{M}_\lambda(\mathbb{I});$
$P'''_{t,\lambda} \leftarrow \text{recombination of object parameters}(P''_{t,\lambda}), P'''_{t,\lambda} \in \mathcal{M}_\lambda(\mathbb{I});$
$P''''_{t,\lambda} \leftarrow \text{mutation of object parameters}(P'''_{t,\lambda}), P''''_{t,\lambda} \in \mathcal{M}_\lambda(\mathbb{I});$
for ($i = 1$ to k) do
$P''''_{t,\lambda} \leftarrow \text{evaluate objective values } f_i;$
end for
$P'''_{t,\lambda} \leftarrow \text{NSGA fitness assignment \{See Algorithm 3.5\}};$
$P_{(t+1),\mu} \leftarrow \text{select}(P'''_{t,\lambda}), P_{(t+1),\mu} \in \mathcal{M}_\mu(\mathbb{I});$
$t \leftarrow t + 1;$
end for

Anmerkung: oft gilt $\lambda = \mu$

Übung

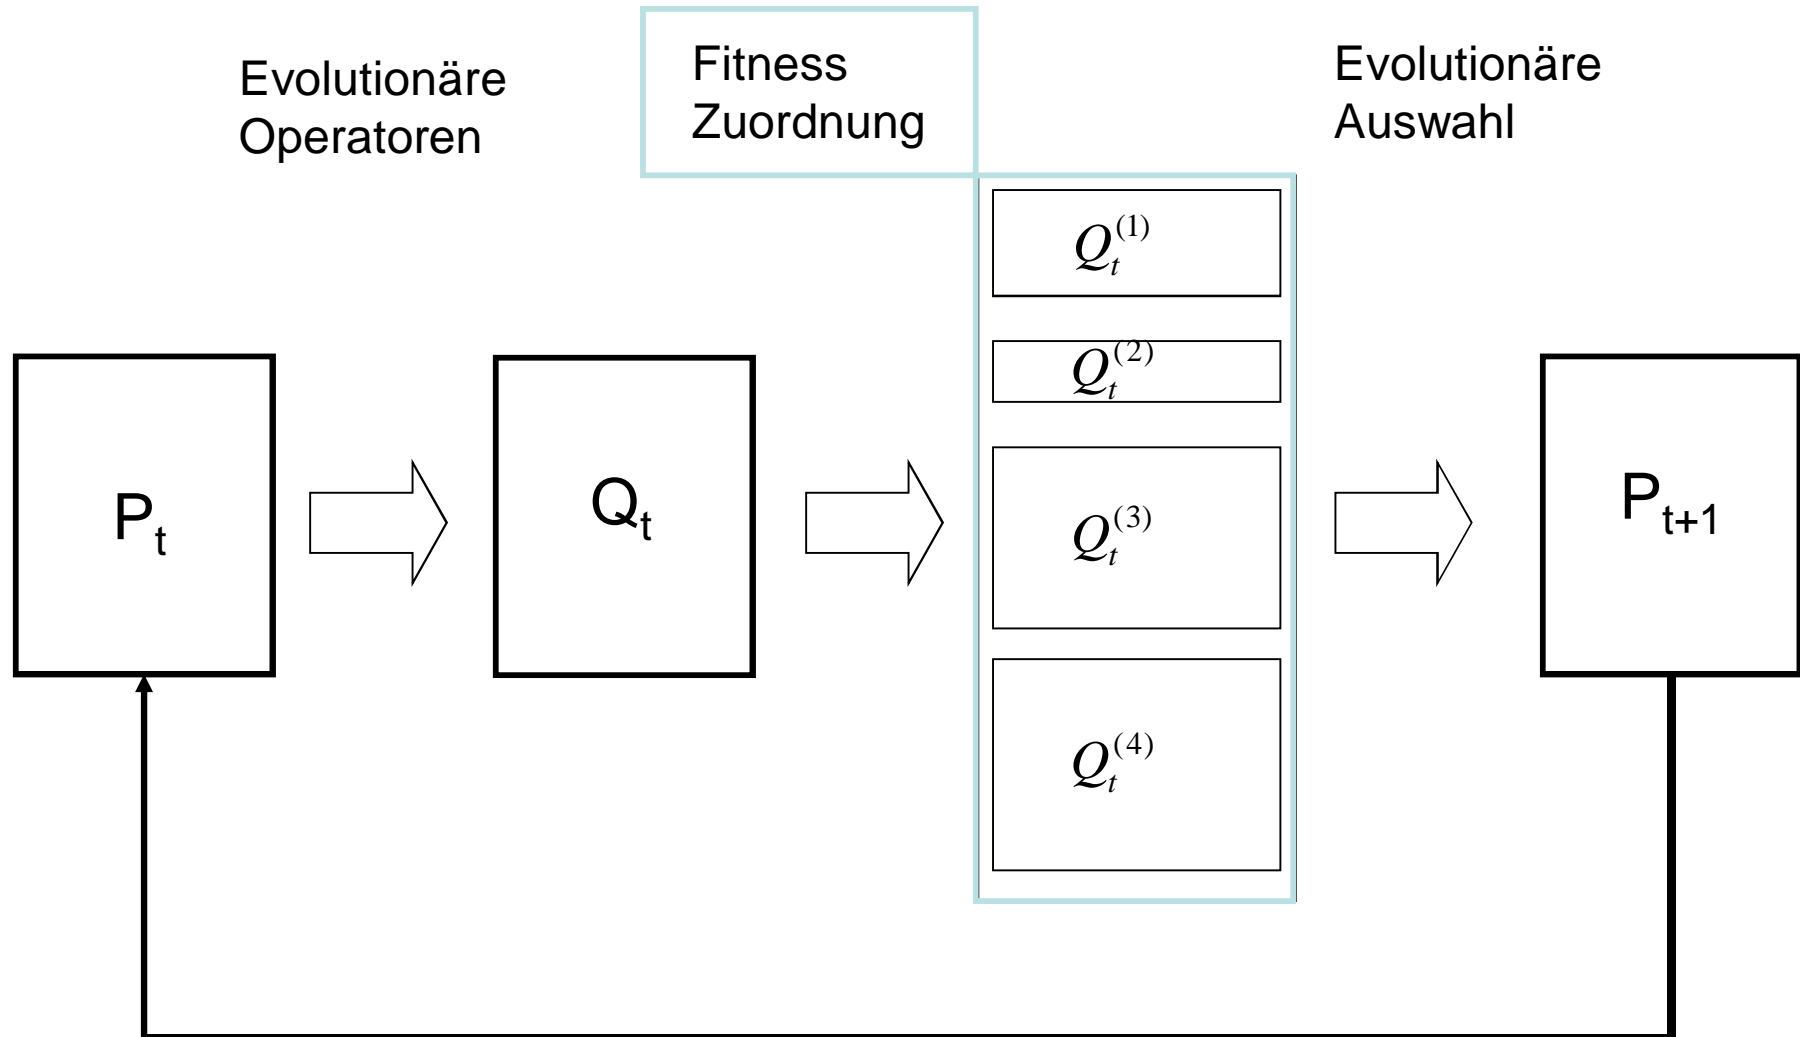
- Welche Gemeinsamkeiten hat eine Evolutionsstrategie und NSGA?
- Ist NSGA ein elitärer Algorithmus? Begründen Sie!

Zwei-Punkte Mutation

- Rechenberg hat diese Mutationsform publiziert
- Funktionsweise ist rein zufällig (r wird zufällig gewählt)

$$\tilde{\sigma} = \begin{cases} \sigma \cdot \alpha, & \text{wenn } r \leq 0,5 \\ \sigma / \alpha, & \text{wenn } r > 0,5 \end{cases}, \alpha > 1 \text{ und } r \in [0,1[$$

NSGA - Schema



NSGA Fitness Zuordnung

Algorithm 3.5 NSGA Fitness Assignment.

Choose a small positive number ϵ ;

$F_{min} = \lambda + \epsilon$;

Classify population P_t according to non-domination: $(P_t^{(1)}, P_t^{(2)}, \dots, P_t^{(\Upsilon)}) = \text{Sort}(P_t, \preceq_p)$

{We assume that Υ fronts exist};

for ($j = 1$ to Υ) **do**

$F_{newMin} = F_{min}$;

for all ($a \in P_t^{(j)}$) **do**

 Assign rank fitness $F^r(a) = F_{min} - \epsilon$;

 Calculate niche count nc_a among solutions of $P_t^{(j)}$ only; {See Algorithm 3.6.}

 Calculate fitness $F(a) = \frac{F^r(a)}{nc_a}$;

$F_{newMin} = \min(F(a), F_{newMin})$;

end for

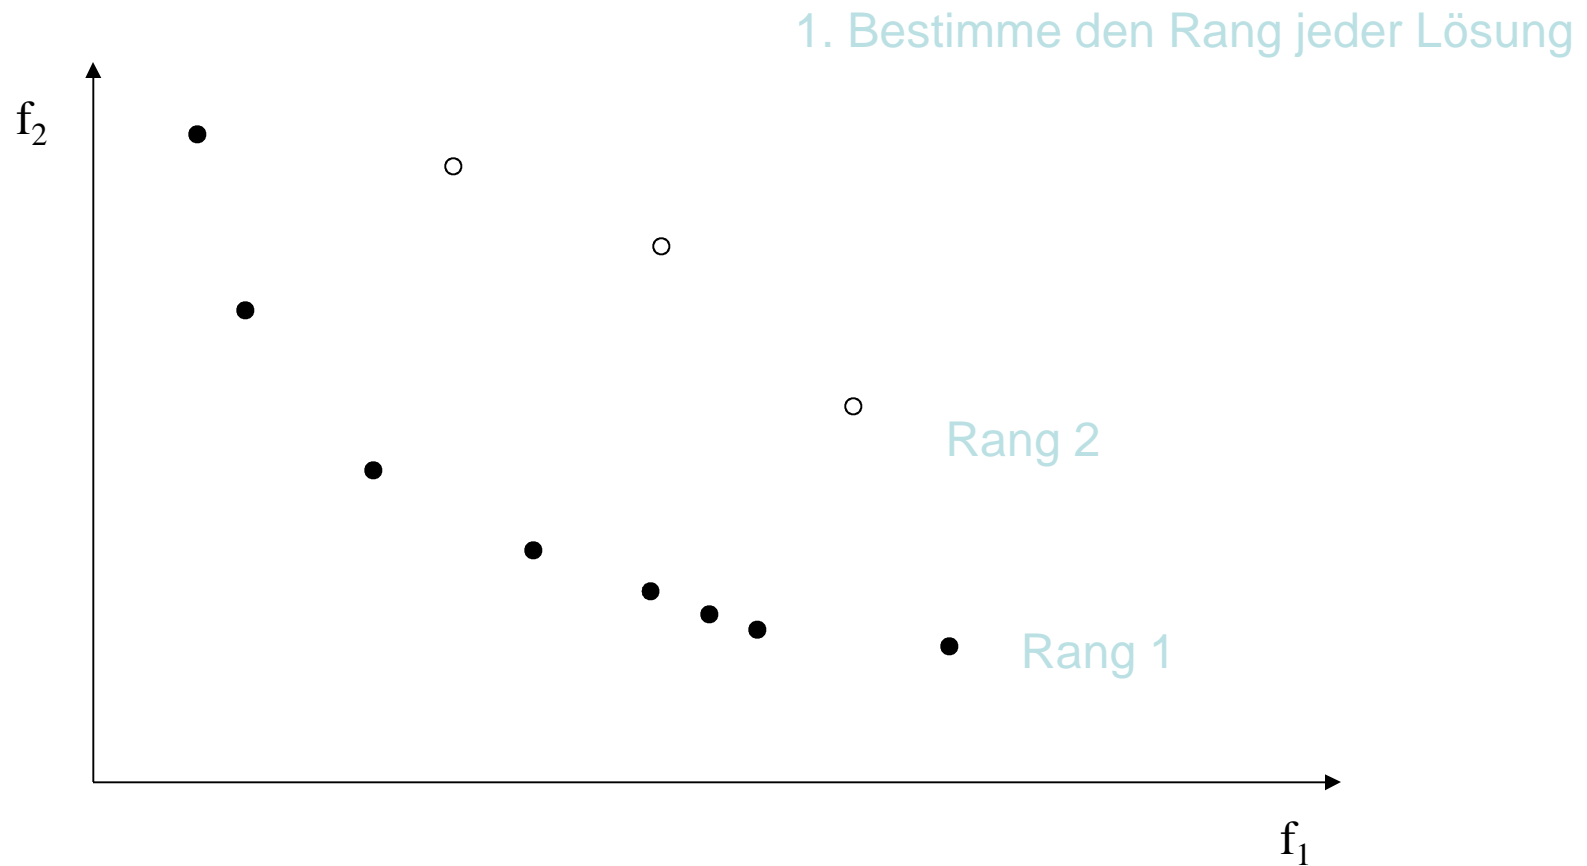
$F_{min} = \min(F_{newMin}, F_{min})$;

end for

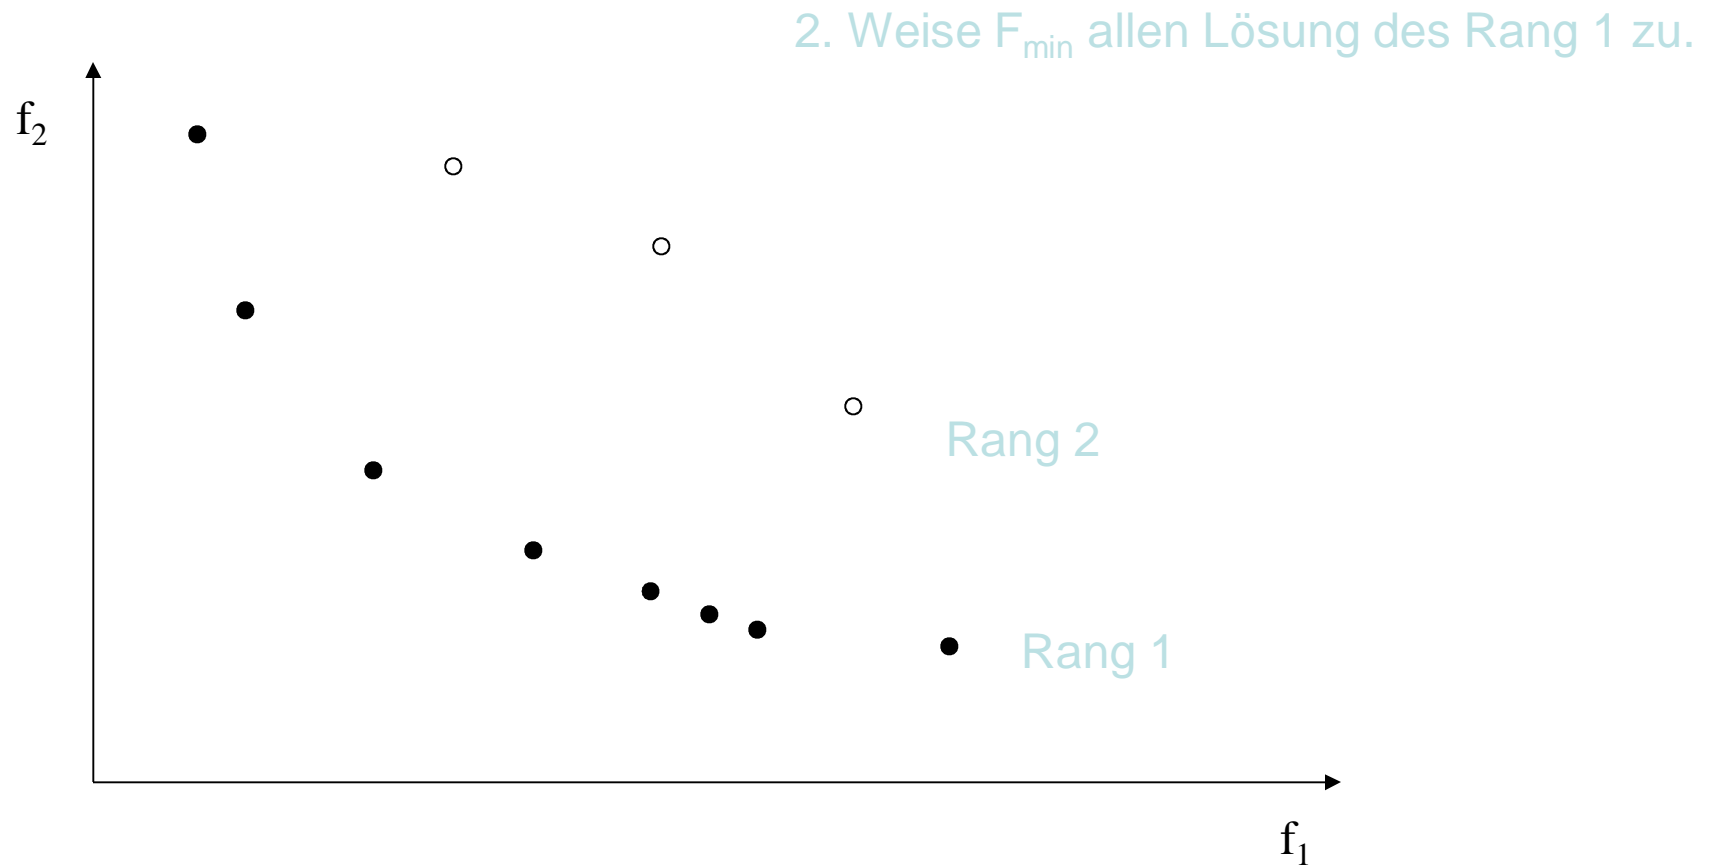
Übung

- Wozu wird ε genutzt?
- Kann $\varepsilon > \lambda$ sein?

NSGA Fitness-Zuordnung



NSGA Fitness-Zuordnung




NSGA Fitness-Zuordnung

3. Berechne niche count nc_q für alle Lösungen q mit Rang 1.

$$Sh(d_{ij}) = \begin{cases} 1 - \left(\frac{d_{ij}}{\sigma_{share}} \right)^2, & \text{if } d_{ij} < \sigma_{share}; \\ 0 & \text{sonst} \end{cases}$$

$$d_{ij} = \sqrt{\sum_{k=1}^m \left(\frac{y_k^{(i)} - y_k^{(j)}}{y_k^{\max} - y_k^{\min}} \right)^2}$$

$$nc_q = 1 + \sum_{i \in R_t^{(j)}, i \neq q} Sh(d_{iq})$$




Übung

- Geben Sie die kleinste obere Grenze für σ_{share} an!
- Erfolgt die Fitness-Zuordnung auch in der Pareto-Front oder auch in der Pareto-Menge?

NSGA Fitness-Zuordnung

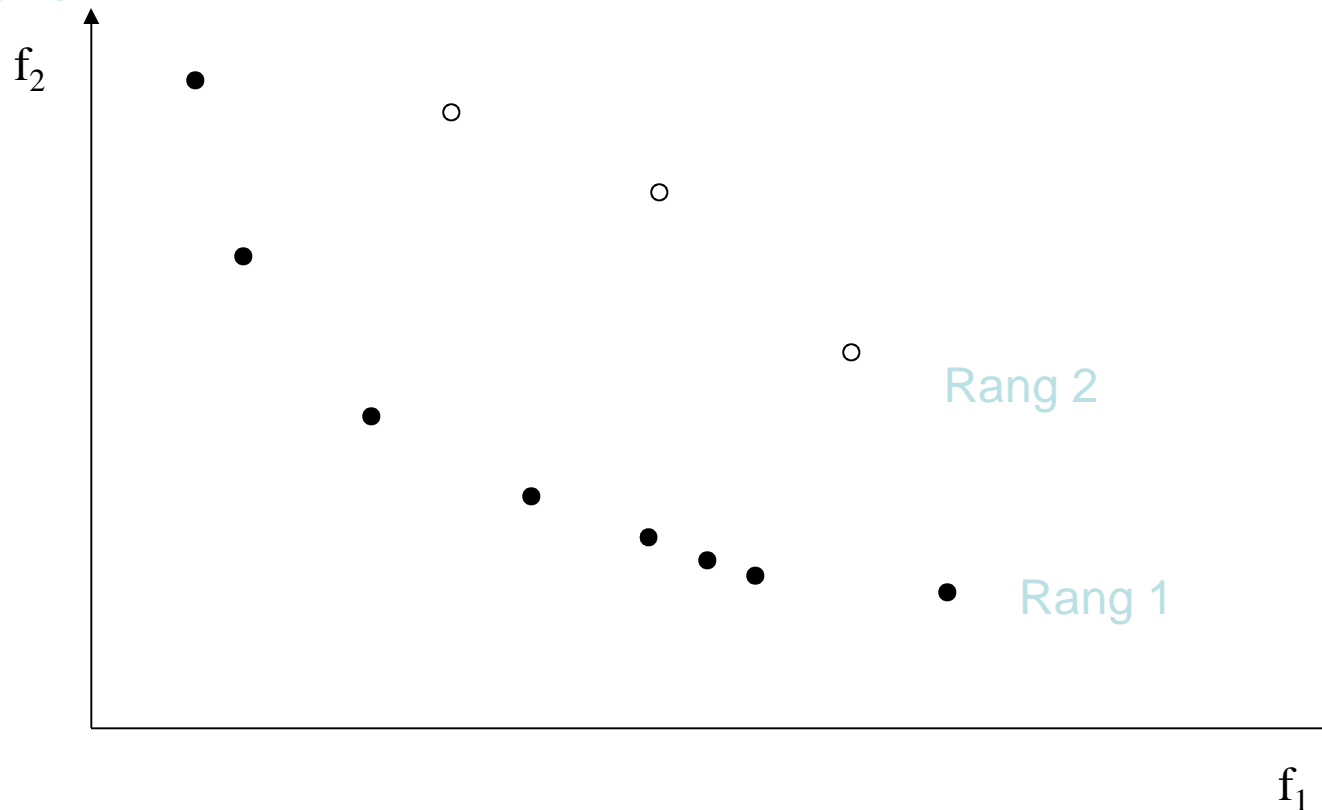
4. Passe alle Fitness-Werte aller
Lösungen des gegebenen Rangs an



NSGA Zuordnung

5. Weise eine Fitness kleiner als der kleinste Fitnesswerte des gegebenen Rangs den Lösungen des nächsten Rangs zu.

$$F_{nextRank} = \min_q (F_{new,q}) - \varepsilon; \quad \varepsilon > 0$$



NSGA Zusammenfassung

- Vorteile
 - Fitness-Zuordnung gemäss des Rangs der nicht-dominierten Front
 - Einführung eines Diversitätserhaltungsoperators (Niche count)
- Nachteile
 - Der Parameter σ_{share} muss vorher definiert sein
 - Nicht-elitärer Algorithmus


Mehr-kriterielle Evolutionäre Algorithmen (Beispiele)

- Nicht-elitäre Algorithmen
 - Vector Evaluated Genetic Algorithm (VEGA)
 - Non-dominated Sorting Genetic Algorithm (NSGA)
 - Predator-Prey Evolution Strategy
 - sehr viele andere
- Elitäre Algorithmen
 - Elitist Non-dominated Sorting Genetic Algorithm (NSGA-II)
 - Strength Pareto Evolutionary Algorithm (SPEA 2)
 - S metric selection Multi-objective Evolutionary Algorithm (SMS-EMOA)
 - Indicator Based Evolutionary Algorithm (IBEA)
 - viele andere

Predator-Prey (Räuber-Beute) Evolution Strategy

- Vollkommen anderer Ansatz als herkömmliche Optimierungsmethoden
- Vorgestellt von Laumann 1998
- Verwendet das Konzept der Pareto-Dominanz nicht
- Beute-Objekte repräsentieren die gefundenen Lösungen
- Jäger sind mit einer Optimierungsfunktion assoziiert und versuchen diese zu verbessern


Predator-Prey Initialisierung



Übung


- Definieren Sie “ungerichteter Graph”!
- Worin besteht der Unterschied zu einem Baum?

Predator-Prey Funktionsweise




1. Die schlechtestes angrenzende Lösung wird ermittelt (Maximierung) und gelöscht.

Predator-Prey Funktionsweise



2. Eine zufällige andere angrenzende Lösung wird ermittelt und zur Mutation genutzt um die Lösung zu ersetzen.

Predator-Prey Funktionsweise



3. Der Jäger bewegt sich zufällig in eine Richtung.

Predator-Prey Optimierung

- Alle Jäger können sich unabhängig voneinander im Graphen bewegen
- Der Algorithmus erlaubt eine asynchrone Optimierung.
- Der Algorithmus endet in der Regel nach einer vorher festgelegten Anzahl Iterationen.
- Häufig wird die Mutationsstärke am Anfang sehr hoch gewählt und dann pro Iteration um 1% abgesenkt.

Predator-Prey Zusammenfassung

- Vorteile
 - Implementierung ist sehr einfach, da die einzelnen Schritte sehr einfach sind
 - Bevorzugt keine bestimmten Pareto-optimalen Lösungen
 - Kann asynchron ablaufen
- Nachteile
 - Kein direkter Mechanismus der die Pareto-front sicherstellt.
 - Das Verhältnis der Anzahl zwischen Räubern und Beuten ist sehr sensitiv und daher schwer zu wählen

Mehr-kriterielle Evolutionäre Algorithmen (Beispiele)

- Nicht-elitäre Algorithmen
 - Vector Evaluated Genetic Algorithm (VEGA)
 - Non-dominated Sorting Genetic Algorithm (NSGA)
 - Predator-Prey Evolution Strategy
 - sehr viele andere
- Elitäre Algorithmen
 - Elitist Non-dominated Sorting Genetic Algorithm (NSGA-II)
 - Strength Pareto Evolutionary Algorithm (SPEA 2)
 - S metric selection Multi-objective Evolutionary Algorithm (SMS-EMOA)
 - Indicator Based Evolutionary Algorithm (IBEA)
 - viele andere

Elitist Non-Dominated Sorting Genetic Algorithm (NSGA-II)

- Erweiterung von NSGA im Jahre 2000
- Wie bisher werden zunächst Nachkommen durch Reproduktion aus der Elterngeneration erzeugt
- Dann wird aus der Vereinigung beider Mengen entsprechend des Rangs und mittels eines speziellen Operators ausgewählt um die neue Generation zu erstellen

Übung

- Warum war NSGA nicht-elitär?
- Was könnte also zum Beispiel geändert werden um einen elitären Algorithmus zu erzeugen?

NSGA-II Teil 1

Initialisierung

Algorithm 3.7 Elitist Non-Dominated Sorting Genetic Algorithm (NSGA-II).

$P_{0,\mu} \leftarrow$ initialization, $P_{0,\mu} \in \mathcal{M}_\mu(\mathbb{I})$;
for ($i = 1$ to k) **do**
 $P_{0,\mu} \leftarrow$ evaluate using objective function f_i ;
end for
Assign ranks to all individuals of population $P_{0,\mu}$ according to non-domination;
 $P'_{0,\lambda} \leftarrow$ binary tournament selection based on the rank($P_{0,\mu}$), $P'_{0,\lambda} \in \mathcal{M}_\lambda(\mathbb{I})$;
 $P''_{0,\lambda} \leftarrow$ recombination($P'_{0,\lambda}$), $P''_{0,\lambda} \in \mathcal{M}_\lambda(\mathbb{I})$;
 $Q_{0,\lambda} \leftarrow$ mutation($P''_{0,\lambda}$), $Q_{0,\lambda} \in \mathcal{M}_\lambda(\mathbb{I})$;
for ($i = 1$ to k) **do**
 $Q_{0,\lambda} \leftarrow$ evaluate using objective function f_i ;
end for
 $t \leftarrow 0$;

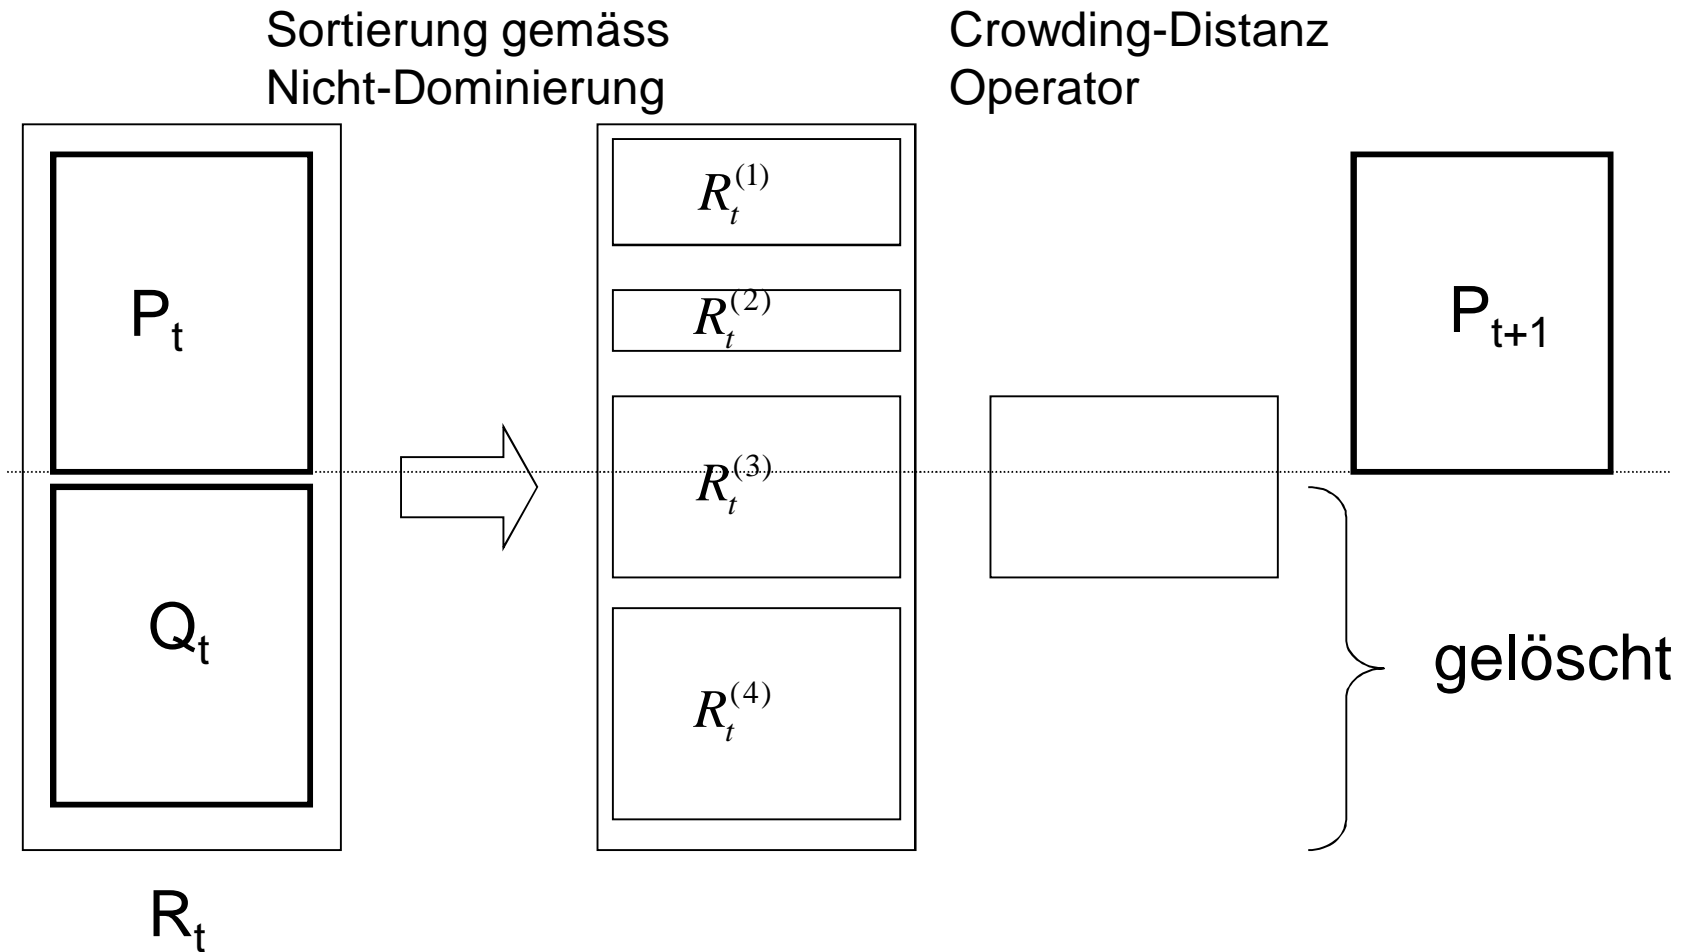
NSGA-II Teil 2

```

for ( $t = 0$  to (Number of Generations-1)) do
   $R_{t,\mu+\lambda} = P_{t,\mu} \cup Q_{t,\lambda}$ ;
  Classify population  $R_{t,\mu+\lambda}$  according to non-domination:
  ( $R_t^{(1)}, R_t^{(2)}, \dots, R_t^{(\Upsilon)} = \text{Sort}(R_{t,\mu+\lambda}, \preceq_p)$ ) {We assume  $\Upsilon$  fronts exist};
   $P_{(t+1),\mu} = \emptyset$ ;
   $c = 1$ ;
  while (( $|P_{(t+1),\mu}| + |R_t^{(c)}| \leq \mu$ )) do
    crowding distance assignment( $R_t^{(c)}$ ) {see Algorithm 3.8};
     $P_{(t+1),\mu} = P_{(t+1),\mu} \cup R_t^{(c)}$ ;
     $c = c + 1$ ;
  end while
   $\text{Sort}(R_t^{(c)}, \preceq_n)$  {sort by crowded comparison operator, see Algorithm 3.9};
   $P_{(t+1),\mu} = P_{(t+1),\mu} \cup R_t^{(c)}[1 : (\mu - |P_{(t+1),\mu}|)]$  {the best  $(\mu - |P_{(t+1),\mu}|)$  elements of  $R_t^{(c)}$ };
   $P'_{(t+1),\lambda} \leftarrow \text{binary tournament selection}(P_{(t+1),\mu}, P'_{(t+1),\lambda} \in \mathcal{M}_\lambda(\mathbb{I}))$ ;
   $P''_{(t+1),\lambda} \leftarrow \text{mutation of strategy parameters}(P'_{(t+1),\lambda}), P''_{(t+1),\lambda} \in \mathcal{M}_\lambda(\mathbb{I})$ ;
   $P'''_{(t+1),\lambda} \leftarrow \text{recombination}(P''_{(t+1),\lambda}), P'''_{(t+1),\lambda} \in \mathcal{M}_\lambda(\mathbb{I})$ ;
   $Q_{(t+1),\lambda} \leftarrow \text{mutation}(P'''_{(t+1),\lambda}), Q_{(t+1),\lambda} \in \mathcal{M}_\lambda(\mathbb{I})$ ;
  for ( $i = 1$  to  $k$ ) do
     $Q_{(t+1),\lambda} \leftarrow \text{evaluate using objective function } f_i$ ;
  end for
   $t \leftarrow t + 1$ ;
end for

```

Schema für NSGA-II



Crowding-Distanz

Algorithm 3.8 NSGA-II Crowding distance assignment procedure for set R .

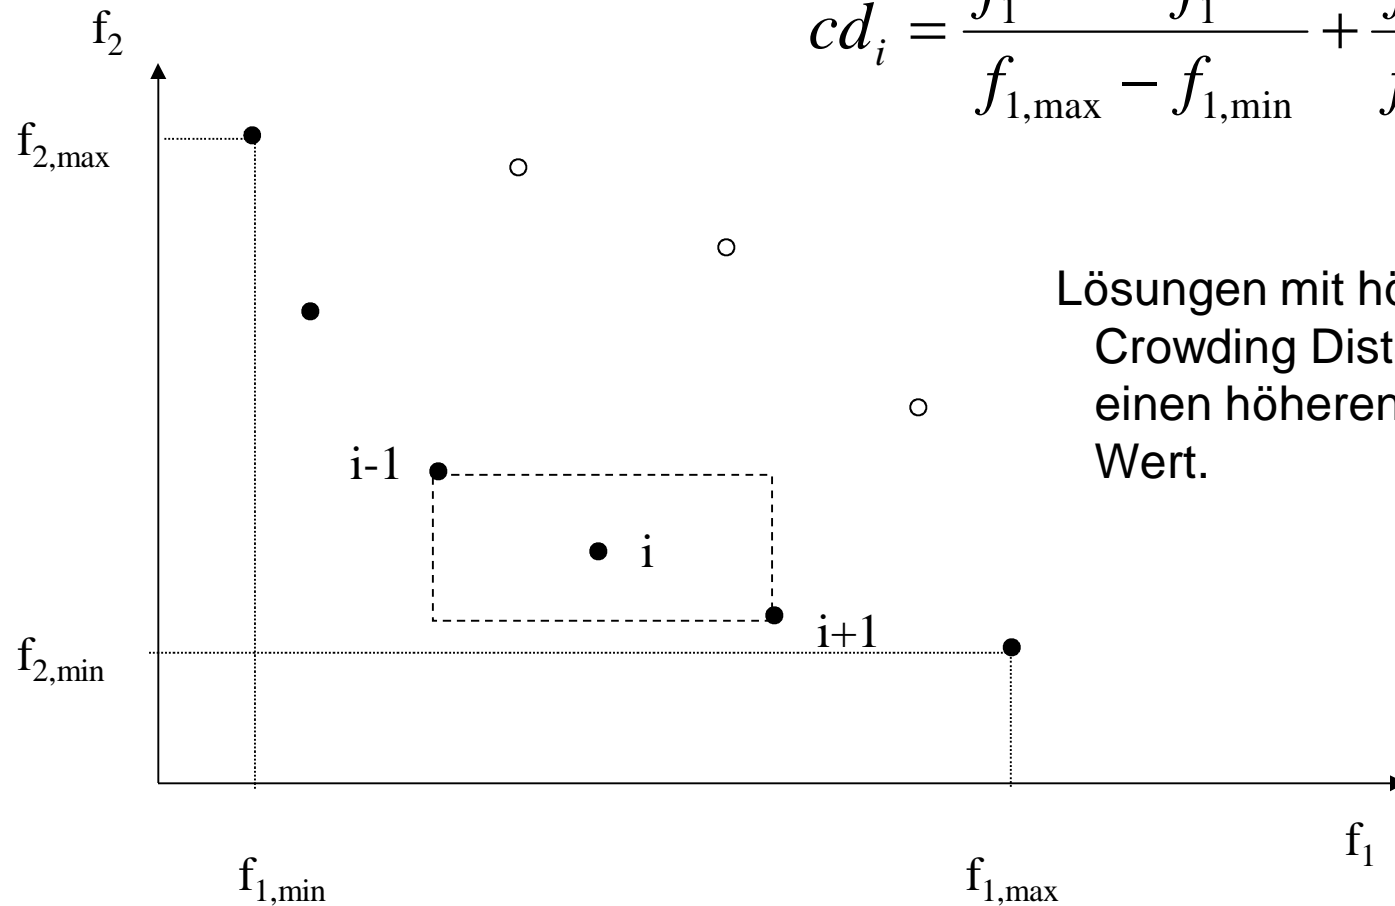
$\Gamma = |R|$ {We assume Γ individuals in set R };
for all ($i \in R$) **do**
 $R[i]_{distance} = 0$ {for each individual i set the crowding distance to 0};
end for
for ($o = 1$ to k) **do**
 Sort R according to increasing objective function f_o : $(R[1_{f_o}], R[2_{f_o}], \dots, R[\Gamma_{f_o}]) = \text{Sort}(R, o)$;
 $V_{f_o}^{max} = R[\Gamma_{f_o}]_{f_o}$;
 $V_{f_o}^{min} = R[1_{f_o}]_{f_o}$;
 $R[1_{f_o}]_{distance} = R[\Gamma_{f_o}]_{distance} = \infty$ {first and last element have distance ∞ };
 for ($j = 2$ to $(\Gamma - 1)$) **do**
 $R[j_{f_o}]_{distance} = R[j_{f_o}]_{distance} + \frac{R[(j-1)_{f_o}]_{f_o} - R[(j+1)_{f_o}]_{f_o}}{V_{f_o}^{max} - V_{f_o}^{min}}$;
 end for
end for

Übung

- Warum haben die Lösungen mit den minimalen und maximalen Werten eine unendliche Crowding-Distanz?

Crowding Distanze Berechnung

$$cd_i = \frac{f_1^{(i+1)} - f_1^{(i-1)}}{f_{1,\max} - f_{1,\min}} + \frac{f_2^{(i-1)} - f_2^{(i+1)}}{f_{2,\max} - f_{2,\min}}$$



Vergleichsoperator

Algorithm 3.9 NSGA-II Crowded Comparison Operator \preceq_n for two individuals a_1 and a_2 .

$a_{1,rank}$ denotes the rank of i ;

$a_{1,distance}$ denotes the crowding distance, see Algorithm 3.8;

if ($a_{1,rank} < a_{2,rank}$) **then**

$a_1 \preceq_n a_2$

else if ($a_{2,rank} < a_{1,rank}$) **then**

$a_2 \preceq_n a_1$

else if ($a_{1,distance} > a_{2,distance}$) **then**

$a_1 \preceq_n a_2$

else

$a_2 \preceq_n a_1$

end if

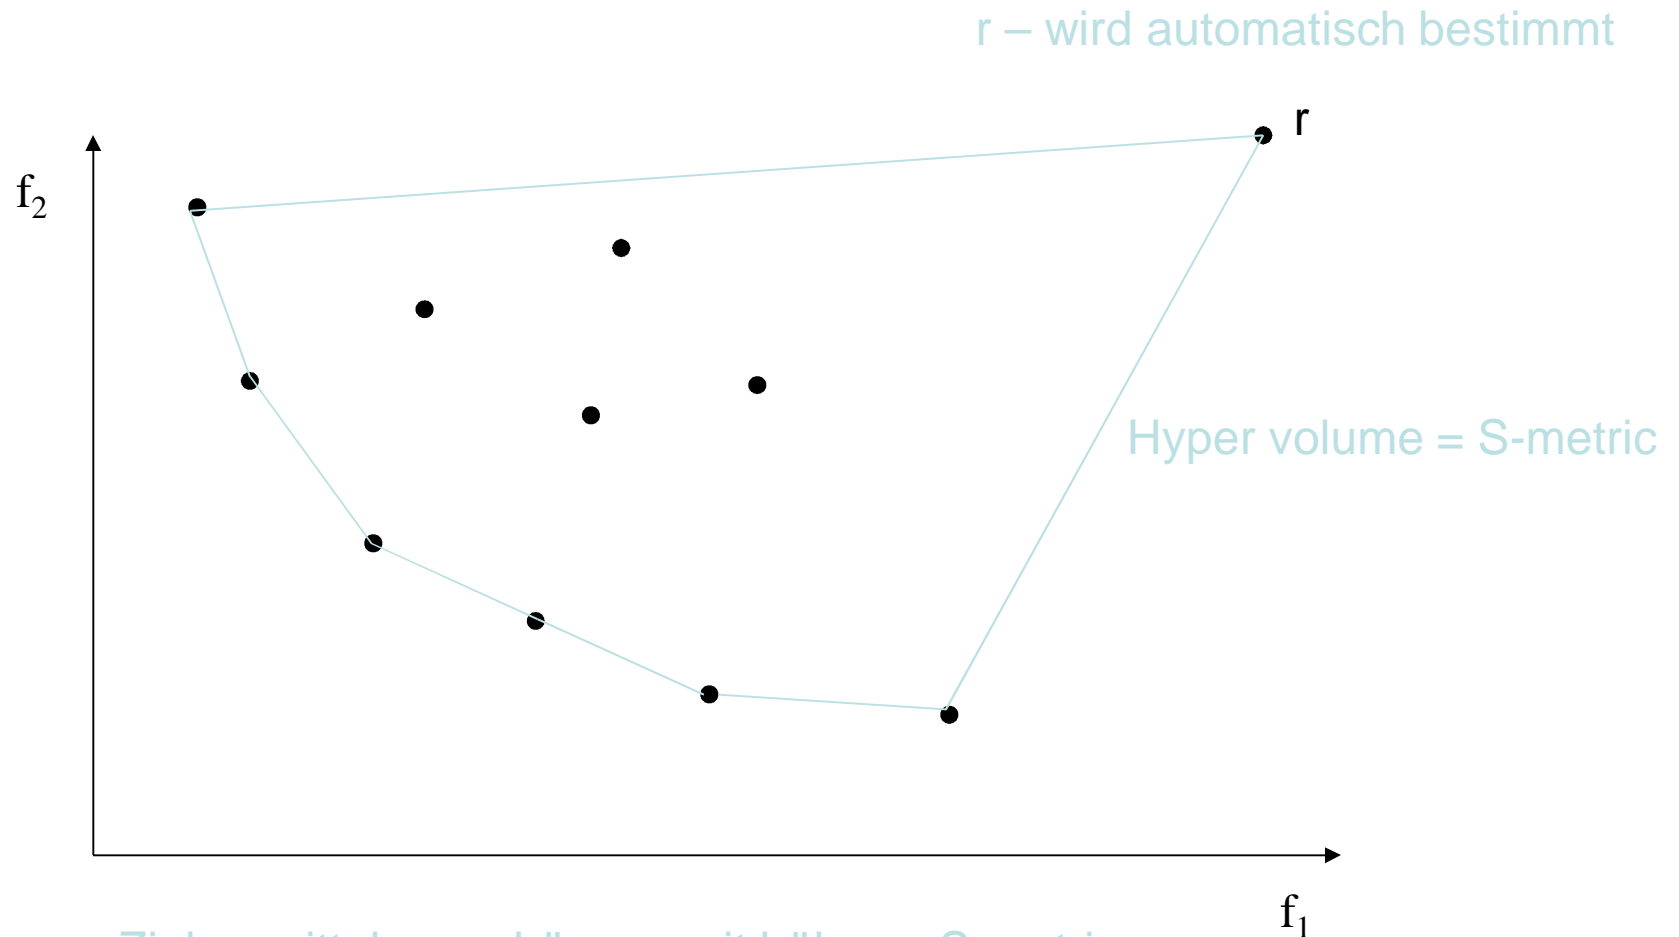
NSGA-II Zusammenfassung

- Vorteile
 - Der Niche-Parameter von NSGA wurde vermieden
 - Turnierselektion sorgt für elitäre Lösungen
- Nachteile
 - Funktioniert nicht sonderlich gut in praktischen Problemfällen mit höheren Dimensionen

Mehr-kriterielle Evolutionäre Algorithmen (Beispiele)

- Nicht-elitäre Algorithmen
 - Vector Evaluated Genetic Algorithm (VEGA)
 - Non-dominated Sorting Genetic Algorithm (NSGA)
 - Predator-Prey Evolution Strategy
 - sehr viele andere
- Elitäre Algorithmen
 - Elitist Non-dominated Sorting Genetic Algorithm (NSGA-II)
 - Strength Pareto Evolutionary Algorithm (SPEA 2)
 - S metric selection Multi-objective Evolutionary Algorithm (SMS-EMOA)
 - Indicator Based Evolutionary Algorithm (IBEA)
 - viele andere

Mehrkriterielle Optimierung mit Evolutionären Algorithmen mittels S-metric




Ziel: ermittle neue Lösung mit höherer S-metric.

Berechnung der S-metric: $O(n \log n + n^{d/2})$


$(\mu+1)$ Algorithmus

Fall 1: Eliminiere das Individuum mit höchstem Dominanzwert.



$(\mu+1)$ algorithm

Fall 2: Eliminiere das Individuum mit kleinstem S-metric Beitrag.



Algorithmus wird nach einer fest deminierten Generationszahl beendet.

Vorlesungsplanung

- 21.02.2012: Einkriterielle Evolutionäre Optimierung I (CF)
- 28.02.2012: Einkriterielle Evolutionäre Optimierung II (CF)
- 06.03.2012: Test (1+2), Mehrkriterielle Evolutionäre Optimierung I (CF)
- 13.03.2012: Statistische Lerntheorie I (JP)
- 20.03.2012: Statistische Lerntheorie II (JP)
- 27.03.2012: Test (4+5), Neuronale Netze (JP)
- 10.04.2012: Mehrkriterielle Evolutionäre Optimierung II (CF)
- 08.05.2012: Genetische Fuzzy Systeme (CF)
- **09.05.2012**: Test (3+7+8), Simulated Annealing und andere Suchmethoden (CF)
- 15.05.2012: Meta-Heuristiken (ACO, PSO) (CF)
- 22.05.2012: Support Vector Maschinen I (JP)
- 29.05.2012: Support Vector Maschinen II (JP)
- 05.06.2012: Test (6+7+12), Clustering (JP)
- 12.06.2012: Lernen und Spieltheorie (JP)
- 26.06.2012: 1. Termin mündliche Prüfungen
- 03.07.2012: 2. Termin mündliche Prüfungen